UNIVERSIDADE TUIUTI DO PARANÁ

Aprendizagem de Máquina

Ciência da Computação

1º Bimestre - Correção

PROVA A

Questão	Resposta	Justificativa
1	B	1ª frente tem rótulo → supervisionado; 2ª não tem rótulo, só busca padrões → não supervisionado
2	C (I e III)	I verdadeira (supervisionado exige rótulo); II falsa (limpeza é ANTES do treino, não depois); III verdadeira (clustering não precisa de rótulo)
3	C	Trata cada problema com a técnica certa: imputação (média/mediana) pros ausentes, correção/remoção pros outliers de idade — sem excluir coluna nem zerar tudo
4	A	I verdadeira (dados incompletos prejudicam modelo) e II verdadeira e explica exatamente o porquê (distorce padrões) → II justifica I
5	D (I, II e III)	Entropia baixa = nó puro; Gini=0 quando puro; árvore profunda = overfitting, poda corrige; IV é falsa: split minimiza entropia, não maximiza
6	E	σ(-0,8) = 1/(1+e^0,8) ≈ 0,31; como 0,31 < limiar 0,5 → classificado como não inadimplente
7	E	Distâncias: A≈2,24, B≈2,24, C≈3,61, D≈5,66. Com k=3, vizinhos mais próximos são A,B,C → maioria (A e B) é classe 0
8	B (I e II)	I verdadeira (acurácia engana em dado desbalanceado); II verdadeira (recall é a métrica certa pra pegar os poucos positivos); III falsa (acurácia sozinha não é confiável aqui)
9	A	C1(1,1) atrai P1(0,1) e P2(1,0); novo centroide = média = (0,5; 0,5)
10	D	K-Means→P (agrupa sem rótulo), KNN→Q (lazy learning, vizinhos), PCA→R (reduz dimensão, variância), SVM→S (hiperplano de máxima margem)
11	≈0,71	Precisão=30/45≈0,667; Recall=30/40=0,75; F1=2×(0,667×0,75)/(0,667+0,75)≈0,706

PROVA B

Questão	Resposta	Justificativa
1	C	1ª frente tem rótulo → supervisionado; 2ª não tem rótulo, só busca padrões → não supervisionado
2	D (I e III)	I verdadeira (supervisionado exige rótulo); II falsa (limpeza é ANTES do treino, não depois); III verdadeira (clustering não precisa de rótulo)
3	D	Trata cada problema com a técnica certa: imputação (média/mediana) pros ausentes, correção/remoção pros outliers de idade — sem excluir coluna nem zerar tudo
4	B	I verdadeira (dados incompletos prejudicam modelo) e II verdadeira e explica exatamente o porquê (distorce padrões) → II justifica I
5	E (I, II e III)	Entropia baixa = nó puro; Gini=0 quando puro; árvore profunda = overfitting, poda corrige; IV é falsa: split minimiza entropia, não maximiza
6	A	σ(-0,8) = 1/(1+e^0,8) ≈ 0,31; como 0,31 < limiar 0,5 → classificado como não inadimplente
7	A	Distâncias: A≈2,24, B≈2,24, C≈3,61, D≈5,66. Com k=3, vizinhos mais próximos são A,B,C → maioria (A e B) é classe 0
8	C (I e II)	I verdadeira (acurácia engana em dado desbalanceado); II verdadeira (recall é a métrica certa pra pegar os poucos positivos); III falsa (acurácia sozinha não é confiável aqui)
9	B	C1(1,1) atrai P1(0,1) e P2(1,0); novo centroide = média = (0,5; 0,5)
10	E	K-Means→P (agrupa sem rótulo), KNN→Q (lazy learning, vizinhos), PCA→R (reduz dimensão, variância), SVM→S (hiperplano de máxima margem)
11	≈0,59	VP=25,FN=15,FP=20,VN=40: Precisão=25/45≈0,556; Recall=25/40=0,625; F1=2×(0,556×0,625)/(0,556+0,625)≈0,588

PROVA C

Questão	Resposta	Justificativa	Questão correspondente - Prova A
1	E	K-Means→P (agrupa sem rótulo), KNN→Q (lazy learning, vizinhos), PCA→R (reduz dimensão, variância), SVM→S (hiperplano de máxima margem) → 1-P, 2-Q, 3-R, 4-S	10
2	C	1ª frente tem rótulo → supervisionado; 2ª não tem rótulo, só busca padrões → não supervisionado	1
3	B	I verdadeira (dados incompletos prejudicam modelo) e II verdadeira e explica exatamente o porquê (distorce padrões) → II justifica I	4
4	B	C1(1,1) atrai P1(0,1) e P2(1,0); novo centroide = média = (0,5; 0,5)	9
5	D (I e III)	I verdadeira (supervisionado exige rótulo); II falsa (limpeza é ANTES do treino, não depois); III verdadeira (clustering não precisa de rótulo)	2
6	A	Distâncias: A≈2,24, B≈2,24, C≈3,61, D≈5,66. Com k=3, vizinhos mais próximos são A,B,C → maioria (A e B) é classe 0	7
7	D	Trata cada problema com a técnica certa: imputação (média/mediana) pros ausentes, correção/remoção pros outliers de idade — sem excluir coluna nem zerar tudo	3
8	E (I, II e III)	Entropia baixa = nó puro (I ✓); Gini=0 quando puro (II ✓); árvore profunda = overfitting, poda corrige (III ✓); IV é falsa: split minimiza entropia, não maximiza	5
9	A	σ(-0,8) = 1/(1+e^0,8) ≈ 0,31; como 0,31 < limiar 0,5 → classificado como não inadimplente	6
10	C (I e II)	I verdadeira (acurácia engana em dado desbalanceado); II verdadeira (recall é a métrica certa pra pegar os poucos positivos); III falsa (acurácia sozinha não é confiável aqui)	8
11	≈0,59	VP=25,FN=15,FP=20,VN=40: Precisão=25/45≈0,556; Recall=25/40=0,625; F1=2×(0,556×0,625)/(0,556+0,625)≈0,588	

PROVA A E B

QUESTÃO 1

Uma operadora de telefonia possui duas frentes de trabalho em ciência de dados. Na primeira, os cientistas usam um histórico de 50 mil clientes, cada um rotulado como "cancelou o plano" ou "não cancelou", para treinar um modelo que preveja o cancelamento de novos clientes. Na segunda frente, os mesmos dados (sem os rótulos de cancelamento) são usados para identificar grupos de clientes com comportamento de consumo semelhante, sem que exista qualquer categoria definida previamente.

Sobre os dois cenários descritos, é correto afirmar que:

A) Ambos são exemplos de aprendizado supervisionado, pois utilizam a mesma base de dados de clientes.

B) A primeira frente é um exemplo de aprendizado supervisionado, pois há uma variável-alvo rotulada; a segunda é um exemplo de aprendizado não supervisionado, pois busca padrões sem rótulos predefinidos.

C) A primeira frente é um exemplo de aprendizado não supervisionado, pois lida com um problema de classificação; a segunda é supervisionada, pois agrupa dados semelhantes.

D) Ambos os cenários são exemplos de aprendizado por reforço, já que a operadora ajusta suas decisões de negócio ao longo do tempo.

E) Não é possível classificar os dois cenários sem conhecer o algoritmo específico utilizado em cada um.

QUESTÃO 2

Uma fintech está estruturando seu pipeline de Aprendizado de Máquina e discute internamente as etapas do processo. Considere as afirmações a seguir.

I. O aprendizado supervisionado exige que o conjunto de dados de treinamento possua uma variável-alvo (rótulo) conhecida para cada exemplo.

II. A limpeza de dados (tratamento de valores ausentes e outliers) deve ser realizada somente depois de o modelo já estar treinado, para que o processo de aprendizado não seja "contaminado" por decisões humanas prévias.

III. O aprendizado não supervisionado pode ser utilizado para segmentar clientes em grupos de comportamento semelhante, mesmo sem a existência de rótulos prévios que indiquem a que grupo cada cliente pertence.

É correto o que se afirma em:

A) I, apenas.

B) I e II, apenas.

C) I e III, apenas.

D) II e III, apenas.

E) I, II e III.

QUESTÃO 3

Durante a construção de um modelo para prever a evasão de alunos em uma universidade, a equipe de dados identifica que a coluna "horas de estudo semanais" possui 12% de valores ausentes e que a coluna "idade" contém alguns registros de "150 anos" e "-3 anos", claramente decorrentes de erro de digitação no sistema acadêmico.

A conduta mais adequada, do ponto de vista de pré-processamento de dados, é:

A) Manter a base como está, pois algoritmos de Aprendizado de Máquina são capazes de identificar e corrigir automaticamente esse tipo de inconsistência durante o treinamento.

B) Excluir a coluna "idade" por completo, já que qualquer valor inconsistente inviabiliza o uso da variável no restante do processo.

C) Tratar os valores ausentes de "horas de estudo semanais" (por exemplo, via imputação pela média ou mediana) e tratar os registros de "150 anos" e "-3 anos" como outliers, corrigindo-os ou removendo-os antes do treinamento.

D) Substituir todos os valores ausentes e os outliers pelo valor zero, sem qualquer análise adicional, já que essa é a prática padrão da literatura de ciência de dados.

E) Converter as duas colunas para o tipo texto, pois isso elimina automaticamente qualquer problema de valores inconsistentes ou ausentes.

QUESTÃO 4

Considere as asserções a seguir a respeito do pré-processamento de dados em um projeto de Aprendizado de Máquina.

I. Dados de treinamento com muitos valores ausentes não tratados tendem a prejudicar o desempenho de modelos de aprendizado supervisionado.

PORQUE

II. Valores ausentes, quando mantidos sem tratamento, podem ser interpretados incorretamente por determinados algoritmos ou causar erros de processamento, distorcendo os padrões que o modelo deveria aprender a partir dos dados.

A respeito dessas asserções, assinale a opção correta.

A) As asserções I e II são proposições verdadeiras, e a II é uma justificativa correta da I.

B) As asserções I e II são proposições verdadeiras, mas a II não é uma justificativa da I.

C) A asserção I é verdadeira, e a II é falsa.

D) A asserção I é falsa, e a II é verdadeira.

E) As asserções I e II são proposições falsas.

QUESTÃO 5

Uma equipe de dados constrói uma árvore de decisão para prever se um cliente vai renovar ou não um seguro. Após o treinamento, o modelo apresenta desempenho quase perfeito na base de treino, mas desempenho ruim em dados novos. Considere as afirmações a seguir sobre árvores de decisão.

I. Quanto menor a entropia de um nó, mais puro ele é, ou seja, mais concentrado em uma única classe.

II. O índice Gini varia entre 0 e 1 (ou 0 e 0,5, dependendo da formulação), sendo igual a 0 quando o nó é totalmente puro.

III. Árvores muito profundas tendem a se ajustar excessivamente aos dados de treinamento (overfitting), e a poda (pruning) é uma técnica utilizada para mitigar esse problema.

IV. O critério de divisão (split) em cada nó é sempre aquele que maximiza a entropia do nó filho resultante.

É correto apenas o que se afirma em:

A) I e II.

B) III e IV.

C) I e III.

D) I, II e III.

E) I, II, III e IV.

QUESTÃO 6

Um banco constrói um modelo de regressão logística para estimar a probabilidade de inadimplência de um cliente com base em seu histórico financeiro. Para um determinado cliente, a combinação linear das variáveis resultou em $z = -0{,}8$. Sabe-se que a função sigmoide é dada por $\sigma(z) = 1 / (1 + e^{-z})$, e que $e^{0{,}8} \approx 2{,}2255$.

Considerando um limiar (threshold) de decisão de 0,5, a probabilidade estimada de inadimplência e a classificação final desse cliente são, respectivamente:

A) ≈ 0,69 — classificado como inadimplente.

B) ≈ 0,31 — classificado como inadimplente.

C) ≈ 0,80 — classificado como não inadimplente.

D) ≈ 0,50 — classificado como inadimplente.

E) ≈ 0,31 — classificado como não inadimplente.

QUESTÃO 7

Considere a base de treinamento a seguir, com as classes já definidas: A(1, 2) — classe 0; B(2, 1) — classe 0; C(6, 5) — classe 1; D(7, 7) — classe 1.

Um novo ponto P(3, 3) deve ser classificado por meio do algoritmo KNN com k = 3, utilizando distância euclidiana.

A classe atribuída a P, com a devida justificativa, é:

A) Classe 1, pois D é o ponto isoladamente mais distante e deve ser desconsiderado, restando maioria da classe 1.

B) Classe 1, pois C e D, os dois pontos mais distantes da origem, definem a classe predominante.

C) Não é possível classificar P sem antes aplicar redução de dimensionalidade (PCA) aos dados.

D) Classe 0, pois A é o único ponto com distância exatamente igual à de B.

E) Classe 0, pois, entre os 3 vizinhos mais próximos de P (A, B eC), dois pertencem à classe 0.

QUESTÃO 8

Uma doença rara está presente em apenas 2% da população testada por um determinado exame automatizado de triagem. Considere as afirmações a seguir sobre a avaliação desse tipo de modelo.

I. Um modelo que sempre prevê "resultado negativo" para qualquer paciente atingiria uma acurácia muito alta, mesmo sendo clinicamente inútil, pois nunca identificaria um caso real da doença.

II. A revocação (recall) mede a proporção de casos positivos reais que foram corretamente identificados pelo modelo, sendo uma métrica especialmente relevante nesse cenário.

III. Em cenários de classes fortemente desbalanceadas como esse, a acurácia isoladamente é a métrica mais confiável para comparar diferentes modelos de classificação.

É correto o que se afirma em:

A) I, apenas.

B) I e II, apenas.

C) II e III, apenas.

D) I, II e III.

E) III, apenas.

QUESTÃO 9

Considere os pontos P1(0, 1), P2(1, 0), P3(4, 5) e P4(5, 3), e os centroides C1 = (1, 1) e C2 = (4, 4) de um algoritmo K-means com k = 2.

Após atribuir cada ponto ao centroide mais próximo (distância euclidiana) e recalcular os centroides como a média dos pontos de cada cluster, o novo centroide C1 é:

A) (0,5; 0,5)

B) (1, 1)

C) (2, 2)

D) (4,5; 4)

E) (0, 1)

QUESTÃO 10

Associe cada algoritmo listado na Coluna 1 à definição tecnicamente correspondente na Coluna 2.

Coluna 1

1. K-Means
2. KNN (K-Nearest Neighbors)
3. PCA (Análise de Componentes Principais)
4. SVM (Support Vector Machine)

Coluna 2

F. Algoritmo não supervisionado que particiona os dados em k grupos, atualizando iterativamente a posição de centroides até a convergência, sem utilizar rótulos de classe em nenhuma etapa.

G. Algoritmo supervisionado, do tipo "aprendizado preguiçoso" (lazy learning), que classifica uma nova instância com base na classe majoritária entre suas k observações mais próximas no espaço de atributos, sem construir um modelo explícito na etapa de treinamento.

H. Técnica não supervisionada de redução de dimensionalidade que transforma as variáveis originais em novas componentes ortogonais entre si, ordenadas pela quantidade de variância que explicam dos dados originais.

I. Algoritmo supervisionado que busca o hiperplano que maximiza a margem entre classes distintas, podendo empregar funções de kernel para tratar problemas não linearmente separáveis no espaço original dos atributos.

Assinale a alternativa que apresenta a associação correta entre as colunas:

A) 1-Q, 2-P, 3-R, 4-S

B) 1-P, 2-Q, 3-S, 4-R

C) 1-P, 2-S, 3-R, 4-Q

D) 1-P, 2-Q, 3-R, 4-S

E) 1-R, 2-Q, 3-P, 4-S

QUESTÃO 11

Um sistema de triagem hospitalar foi testado em 100 pacientes, resultando na seguinte matriz de confusão para a classe "caso grave":
VP = 30, FN = 10, FP = 15, VN = 45

O valor do F1-score desse modelo é aproximadamente: _____