Exercícios de Revisão
1º Bimestre

1. Uma startup lança um chatbot que responde e-mails de suporte técnico seguindo regras programadas e, separadamente, testa um sistema que aprende a reconhecer imagens de produtos danificados a partir de milhares de fotos rotuladas por humanos.

Sobre os conceitos de IA, é correto afirmar que:

A) Apenas o chatbot pode ser considerado IA, pois IA exige exclusivamente regras lógicas explícitas.
B) O reconhecedor de imagens não é IA, pois não simula raciocínio humano consciente.
C) O chatbot baseado em regras é um sistema de IA simbólica/baseada em regras, enquanto o reconhecedor de imagens é um exemplo de Aprendizado de Máquina, que extrai padrões a partir de dados.
D) Os dois sistemas são idênticos do ponto de vista técnico, diferindo apenas na linguagem de programação usada.
E) Ambos os sistemas são exemplos de Aprendizado de Máquina, pois todo sistema de IA aprende com dados.

2. Considere as afirmações sobre a hierarquia Dado → Informação → Conhecimento:

I. Um dado é um valor bruto sem contexto interpretativo (ex.: o número "37").
II. Informação é o dado organizado e contextualizado, que responde a perguntas como "o quê", "quem", "quando" (ex.: "a temperatura é 37°C").
III. Conhecimento envolve a capacidade de usar a informação para tomar decisões ou prever situações (ex.: saber que 37°C indica febre e requer atenção médica).
IV. Consciência, atualmente, é uma capacidade plenamente reproduzida por sistemas de Aprendizado de Máquina supervisionado.

É correto o que se afirma em:

A) I e II, apenas.
B) II, III e IV, apenas.
C) I, II e III, apenas.
D) I, III e IV, apenas.
E) I, II, III e IV.

3. Um jornal publica a manchete: "*Chatbot passa no Teste de Turing e prova que máquinas já pensam como humanos, com consciência plena.*" Um professor de Inteligência Artificial contesta publicamente essa afirmação.

A crítica do professor está tecnicamente correta porque:

A) Passar no Teste de Turing comprova cientificamente que a máquina possui consciência.
B) O Teste de Turing exige que o sistema resolva problemas matemáticos complexos para ser aprovado.
C) O Teste de Turing avalia apenas se um interlocutor humano consegue distinguir as respostas da máquina das de um humano em uma conversa; isso não implica que a máquina tenha consciência, compreensão ou inteligência geral (IA forte) — trata-se de simulação de comportamento (IA fraca).
D) Toda IA capaz de conversar fluentemente é, por definição, um exemplo de IA forte.
E) O conceito de IA forte e fraca não tem nenhuma relação com o Teste de Turing.

4. Uma fintech trabalha em três projetos simultâneos:

- Projeto X: prever se um cliente vai inadimplir (sim/não), usando um histórico de clientes já rotulados como "inadimplente" ou "adimplente".
- Projeto Y: agrupar clientes em perfis de consumo sem que existam rótulos prévios.
- Projeto Z: treinar um agente que decide quando aprovar ou negar crédito, recebendo recompensas quando acerta e penalidades quando erra, ajustando sua estratégia ao longo do tempo.

A classificação correta dos tipos de aprendizado é:

A) X: não supervisionado; Y: supervisionado; Z: por reforço.
B) X: por reforço; Y: supervisionado; Z: não supervisionado.
C) X: supervisionado; Y: não supervisionado; Z: por reforço.
D) X: supervisionado; Y: por reforço; Z: não supervisionado.
E) Todos os projetos são exemplos de aprendizado supervisionado, pois todos usam dados históricos.

5. Uma equipe de dados recebeu uma base bruta, cheia de valores ausentes e em escalas diferentes, para construir um modelo preditivo.

Assinale a alternativa que apresenta a sequência **mais coerente** de etapas de um projeto de ML:

A) Avaliar métricas → treinar o modelo → coletar dados → definir o problema.
B) Coletar dados → treinar o modelo → definir o problema → pré-processar dados.
C) Definir o problema → coletar dados → pré-processar dados → dividir em treino/teste → treinar o modelo → avaliar com métricas.
D) Pré-processar dados → definir o problema → avaliar métricas → coletar dados.
E) Treinar o modelo → coletar dados → avaliar métricas → pré-processar dados.

6. Em uma base de clientes, a coluna "idade" tem valor mínimo de 20 e valor máximo de 60 anos. Aplicando a normalização min-max, o valor normalizado de um cliente com 35 anos é:

A) 0,25
B) 0,30
C) 0,375
D) 0,40
E) 0,50

7. Um modelo de diagnóstico foi testado em 100 pacientes, gerando a seguinte matriz de confusão:

	Previsto Positivo	**Previsto Negativo**
Real Positivo	VP = 40	FN = 5
Real Negativo	FP = 10	VN = 45

A revocação (recall) do modelo é aproximadamente:

A) 0,80
B) 0,85
C) 0,89
D) 0,90
E) 0,75

8. Sobre underfitting e overfitting, avalie as afirmações:

I. Um modelo com alto viés (high bias) tende a underfitting, apresentando erro alto tanto no treino quanto no teste.
II. Um modelo com alta variância (high variance) tende a overfitting, memorizando o ruído dos dados de treino e generalizando mal para novos dados.
III. Aumentar a complexidade do modelo sempre reduz simultaneamente o viés e a variância.
IV. Técnicas como regularização e validação cruzada ajudam a controlar o trade-off viés-variância.

É correto o que se afirma em:

A) I e II, apenas.
B) I, III e IV, apenas.
C) I, II e IV, apenas.
D) II e III, apenas.
E) I, II, III e IV.

9. Um cientista de dados plota o erro de treino e o erro de teste em função da complexidade do modelo. Ele observa que, a partir de um certo ponto, o erro de treino continua caindo, mas o erro de teste começa a subir.

Esse comportamento indica que o modelo está entrando em uma região de:

A) Underfitting, sendo necessário aumentar ainda mais a complexidade.
B) Viés ideal, não sendo necessária nenhuma ação.
C) Overfitting, sendo recomendável simplificar o modelo ou aplicar regularização.
D) Erro irredutível, que não pode ser corrigido por nenhuma técnica.
E) Convergência perfeita entre treino e teste.

10. Uma base de dados hospitalar apresenta 15% de registros com valores ausentes na coluna "pressão arterial" e alguns valores de "idade" registrados como 300 anos.

A conduta tecnicamente mais adequada é:

A) Ignorar o problema, pois modelos de ML lidam automaticamente com valores inconsistentes.
B) Excluir toda a base de dados, pois qualquer inconsistência invalida o conjunto.
C) Tratar os valores ausentes (ex.: imputação pela média/mediana) e identificar/tratar os valores de idade como outliers, corrigindo ou removendo-os.
D) Substituir todos os valores ausentes por zero, sem qualquer outra análise.
E) Converter todas as colunas para o tipo texto antes de qualquer tratamento.

11. Um dataset de e-commerce tem duas colunas categóricas: "cor do produto" (valores: azul, vermelho, verde — sem ordem natural) e "nível de satisfação" (valores: baixo, médio, alto — com ordem natural).

A estratégia de codificação mais apropriada é:

A) Aplicar one-hot encoding em ambas, pois toda variável categórica deve virar múltiplas colunas binárias.
B) Aplicar label encoding em "cor do produto" e one-hot encoding em "nível de satisfação".
C) Aplicar one-hot encoding em "cor do produto" (sem ordem) e label encoding (ou encoding ordinal) em "nível de satisfação" (com ordem).
D) Não codificar nenhuma das duas, pois modelos de ML aceitam texto diretamente.
E) Aplicar normalização min-max em ambas, já que são categóricas.

12. Uma imobiliária ajustou um modelo de regressão linear simples para prever o preço de imóveis (em milhares de reais) a partir da área (em dezenas de m^2): **preço = 50 + 8 × área**.

Para um imóvel com área correspondente a x = 10 (ou seja, 100 m^2), o preço previsto pelo modelo é:

A) 58
B) 90
C) 130
D) 100
E) 150

13. Em um modelo de regressão logística para prever churn (cancelamento), a combinação linear das variáveis para um cliente resultou em z = 1,5. A função sigmoide é dada por $\sigma(z) = 1 / (1 + e^{-z})$, com $e^{-1{,}5} \approx 0{,}223$.

A probabilidade estimada de churn para esse cliente é aproximadamente:

A) 0,18
B) 0,65
C) 0,82
D) 0,50
E) 0,95

14. Em um nó de uma árvore de decisão há 10 exemplos: 6 da classe "aprovado" e 4 da classe "reprovado".

Considerando $\log_2(0{,}6) \approx -0{,}737$ e $\log_2(0{,}4) \approx -1{,}322$, a entropia desse nó é aproximadamente:

A) 0,00
B) 0,881
C) 0,971
D) 0,50
E) 1,000

15. Considere os pontos de treino no plano (com suas classes): A(1,1) classe 0; B(2,2) classe 0; C(6,6) classe 1; D(7,8) classe 1; E(1,6) classe 0.

Um novo ponto P(4,5) deve ser classificado usando **KNN com k = 3** e distância euclidiana.

A classe atribuída a P e a justificativa corretas são:

A) Classe 1, pois D é o ponto mais próximo isoladamente.
B) Classe 1, pois todos os vizinhos mais próximos pertencem à classe 1.
C) Classe 0, pois entre os 3 vizinhos mais próximos (C, E, B), dois pertencem à classe 0.
D) Não é possível classificar sem normalizar os dados antes.
E) Classe 0, pois A é o ponto mais próximo.

16. Sobre Support Vector Machines (SVM), avalie as afirmações:

I. O objetivo do SVM é encontrar o hiperplano que maximiza a margem entre as classes.
II. Vetores de suporte são os pontos mais distantes do hiperplano de separação, e por isso são ignorados no treinamento.
III. Funções de kernel (como o RBF) permitem que o SVM separe dados que não são linearmente separáveis no espaço original.

É correto apenas o que se afirma em:

A) I.
B) I e II.
C) I e III.
D) II e III.
E) I, II e III.

17. Considere os pontos P1(1,2), P2(2,1), P3(4,5), P4(5,4) e os centroides iniciais C1 = (1,1) e C2 = (5,5).

Após atribuir cada ponto ao centroide mais próximo (por distância euclidiana) e recalcular os centroides (média dos pontos do cluster), o **novo centroide C1** é:

A) (1,1)
B) (3,3)
C) (1,5; 1,5)
D) (2,2)
E) (4,5; 4,5)

18. Uma equipe de dados trabalha com um dataset de 50 variáveis (colunas) e decide aplicar PCA antes de treinar um modelo.

Sobre o PCA, é correto afirmar que:

A) Ele elimina variáveis aleatoriamente até restar um número desejado de colunas.
B) Ele só pode ser aplicado a variáveis categóricas.
C) Ele cria novas variáveis (componentes principais), combinações lineares das originais, ordenadas pela quantidade de variância que explicam, permitindo reduzir a dimensionalidade com perda mínima de informação.
D) Ele aumenta o número de variáveis para melhorar a precisão do modelo.
E) Ele substitui completamente a etapa de normalização dos dados.

19. Uma empresa de telecomunicações quer prever quais clientes vão cancelar o serviço (churn) no próximo mês. A base tem variáveis numéricas em escalas muito diferentes (ex.: "tempo de contrato" em meses e "gasto mensal" em reais), variáveis categóricas nominais (ex.: "plano contratado") e um forte desbalanceamento entre clientes que cancelam (10%) e que não cancelam (90%).

Considerando o pipeline de ML, a alternativa que apresenta a abordagem tecnicamente mais adequada é:

A) Usar os dados brutos diretamente no modelo, pois algoritmos de ML corrigem automaticamente escalas e desbalanceamento.
B) Ignorar a etapa de pré-processamento e escolher a métrica de acurácia, pois ela é sempre suficiente para avaliar qualquer modelo de classificação.
C) Aplicar normalização/padronização nas variáveis numéricas, one-hot encoding na variável categórica nominal, e avaliar o modelo com métricas como precisão, revocação e F1-score (em vez de apenas acurácia), já que a acurácia pode ser enganosa em bases desbalanceadas.
D) Aplicar label encoding na variável "plano contratado" mesmo sem ordem natural entre os planos, pois é matematicamente equivalente ao one-hot encoding.
E) Usar apenas a matriz de confusão como critério de pré-processamento dos dados.

20. Sobre a construção e avaliação de modelos de Aprendizado de Máquina, avalie as afirmações:

I. Um modelo com acurácia de 95% em uma base onde 95% dos exemplos pertencem à classe majoritária pode, ainda assim, ser um modelo ruim, o que justifica o uso de métricas como precisão, revocação e F1-score.
II. A normalização dos dados é particularmente importante para algoritmos baseados em distância, como o KNN, pois variáveis em escalas diferentes podem dominar o cálculo da distância.
III. Overfitting pode ser identificado quando o erro no conjunto de treino é muito baixo, mas o erro no conjunto de teste é significativamente mais alto.
IV. A escolha do valor de k no K-means e no KNN não tem nenhum impacto no desempenho final do modelo.

É correto o que se afirma em:

A) I e II, apenas.
B) II, III e IV, apenas.
C) I, II e III, apenas.
D) I, III e IV, apenas.
E) I, II, III e IV.

21. ENADE 2021 - As técnicas de aprendizado de máquinas empregam um princípio de inferência denominado indução, no qual é possível obter conclusões genéricas a partir de um conjunto particular de exemplos. Estas técnicas de aprendizados indutivos podem ser divididas em dois principais tipos: os supervisionados e os não supervisionados.

No aprendizado supervisionado é fornecida uma referência do objetivo a ser alcançado, isto é, um treinamento com o conhecimento do ambiente. Diferentemente do aprendizado supervisionado, o não supervisionado não utiliza referências, ou seja, não ocorre um treinamento com o conhecimento do ambiente. *(PELLUCCI P. R. S. et al. Utilização de técnicas de aprendizado de máquina no reconhecimento de entidades nomeadas no português. Belo Horizonte. E-xacta, v. 4, n. 1, p. 73-81, 2011, adaptado)*.

Considerando as informações do texto, avalie as afirmações a seguir.

I. A regressão linear é um exemplo de modelo baseado no aprendizado supervisionado.
II. A diferença entre a saída desejada e a saída gerada é o valor do erro de um aprendizado não supervisionado.
III. O aprendizado não supervisionado é mais utilizado quando o entendimento dos dados é feito por meio de reconhecimento de padrões.
IV. O aprendizado supervisionado é capaz de tomar decisões precisas ao receber novos dados a partir de um treinamento com dados conhecidos.

É correto apenas o que se afirma em

A) I e III.
B) II e III.
C) I, III e IV.
D) II e IV.
E) I, II e IV.

22. Assinale Verdadeiro ou Falso.

A. Um hospital implementa um chatbot que segue um fluxograma fixo de perguntas ("Você tem febre? Sim/Não → pergunta a seguinte") para triagem, enquanto outro sistema aprende a identificar pneumondia em raios-X a partir de milhares de exames rotulados por radiologistas. É correto afirmar que o primeiro sistema é um exemplo de IA baseada em regras (simbólica), enquanto o segundo é um exemplo de Aprendizado de Máquina.

B. Em um sistema de e-commerce, o valor bruto "37" armazenado em uma coluna não tem significado por si só; ao ser contextualizado como "37 unidades vendidas na última hora", esse valor se torna informação; e ao ser usado para prever que o estoque vai esgotar em 2 horas e disparar um pedido de reposição automático, isso caracteriza conhecimento aplicado.

C. Uma seguradora usa um histórico de sinistros rotulados como "fraude" ou "não fraude" para treinar um modelo que classifica novos sinistros — isso é aprendizado supervisionado. Já separado disso, ela também usa um algoritmo sem rótulos para agrupar clientes em perfis de risco similares — isso é aprendizado não supervisionado. Os dois projetos podem coexistir na mesma empresa, com objetivos distintos.

D. Um cientista de dados percebe que seu modelo de previsão de vendas tem erro baixíssimo nos dados de treino, mas erro muito alto em dados novos. Isso é um sintoma clássico de overfitting (alta variância), e uma das soluções possíveis é aplicar regularização ou aumentar o volume de dados de treinamento.

E. Em um sistema de detecção de fraude bancária, mesmo obtendo 98% de acurácia, o banco decide não confiar apenas nessa métrica, pois apenas 2% das transações são realmente fraudulentas — nesse cenário, um modelo "preguiçoso" que classifica tudo como "não fraude" já atingiria 98% de acurácia sem detectar fraude nenhuma. Por isso, métricas como recall e F1-score são mais informativas aqui.

F. Uma base de dados de RH tem registros de "idade" com valores como 200 e -5 anos, claramente erros de digitação. Antes de treinar qualquer modelo, é necessário tratar esses valores como outliers/inconsistências, seja corrigindo-os, seja removendo-os, sob pena de distorcer o aprendizado do modelo.

G. Uma imobiliária tem uma coluna "área do imóvel" variando de 20 m² a 500 m² e outra coluna "número de quartos" variando de 1 a 6. Como esses atributos têm escalas muito diferentes, aplicar normalização (min-max ou z-score) antes de usar um algoritmo baseado em distância, como o KNN, é uma prática recomendada para evitar que a variável de maior escala domine o cálculo.

H. Em uma pesquisa de satisfação, a variável "nível de escolaridade" (fundamental, médio, superior) possui uma ordem natural entre suas categorias, o que a torna mais adequada para uma codificação ordinal (label encoding com ordem) do que para one-hot encoding, que é mais indicado para variáveis nominais sem ordem, como "estado civil".

I. Em um modelo de regressão logística que estima a probabilidade de um cliente cancelar uma assinatura, a saída da função sigmoide sempre estará entre 0 e 1, podendo ser interpretada como uma probabilidade, e o modelo define uma fronteira de decisão (geralmente 0,5) para classificar o cliente como "vai cancelar" ou "não vai cancelar".

J. Em uma árvore de decisão que classifica clientes como "bom pagador" ou "mau pagador", um nó cuja distribuição de exemplos é 100% de uma única classe (por exemplo, todos "bom pagador") tem entropia igual a zero, indicando que esse nó já é totalmente puro e não precisa de mais divisões.

K. Uma clínica veterinária usa o KNN para classificar animais por peso (em kg) e altura (em cm), sem normalizar os dados antes. Como o KNN calcula probabilidades estatísticas independentes por atributo (e não distâncias diretas entre os pontos), a diferença de escala entre "peso" e "altura" não interfere no resultado da classificação.

L. Em um SVM treinado para separar e-mails em "spam" e "não spam", os vetores de suporte são os pontos de treinamento mais distantes do hiperplano de separação — por isso, durante o treinamento, esses pontos são descartados do cálculo, já que a margem é definida apenas pelos exemplos mais próximos da região central das classes.

M. Uma rede de varejo aplica o K-means para segmentar clientes em 4 grupos de consumo. Como o algoritmo minimiza a distância dentro dos clusters de forma determinística, diferentes inicializações aleatórias dos centroides sempre convergem para exatamente o mesmo agrupamento final, garantindo um ótimo global independentemente do ponto de partida.

N. Uma equipe de dados aplica PCA a um conjunto de 40 variáveis financeiras rotuladas como "empresa lucrativa" ou "empresa deficitária", pois o PCA utiliza esses rótulos para decidir quais combinações lineares de variáveis maximizam a separação entre as duas classes, sendo, portanto, uma técnica de aprendizado supervisionado.

O**.** Ao perceber que seu modelo de previsão de churn está com desempenho ruim tanto no treino quanto no teste (underfitting), um cientista de dados aumenta a complexidade do modelo (mais parâmetros, mais profundidade). Essa ação sempre reduz simultaneamente o viés e a variância do modelo, eliminando por completo o trade-off entre os dois.

P. Uma imobiliária treina um modelo de regressão linear simples para prever o preço de um imóvel a partir do bairro em que ele está localizado (uma variável textual como "Centro", "Zona Sul", "Zona Norte"), inserindo o texto diretamente na fórmula da regressão, já que algoritmos de regressão linear processam nativamente variáveis categóricas em formato de texto sem qualquer transformação prévia.

Q. Em um sistema de diagnóstico de uma doença rara, presente em apenas 1% da população testada, a acurácia é sempre a métrica mais adequada para avaliar o modelo, independentemente do desbalanceamento entre as classes, pois ela reflete diretamente a qualidade de qualquer classificador, seja qual for a proporção de casos positivos e negativos.

R. Em um sistema de recomendação que representa produtos como vetores de características, dois vetores perpendiculares entre si (produto escalar igual a zero) indicam que os produtos são extremamente parecidos entre si, já que o produto escalar mede diretamente o grau de semelhança total entre dois vetores, sendo maximizado quando eles são ortogonais.

S. Uma fintech treina um agente que aprende a decidir entre aprovar ou negar crédito recebendo recompensas e penalidades ao longo do tempo (aprendizado por reforço). Esse tipo de aprendizado exige, assim como o aprendizado supervisionado, uma base de dados previamente rotulada com a decisão "correta" para cada caso, servindo como referência direta de comparação em cada passo de treinamento.

T. Em uma pesquisa de mercado, a variável nominal "cor do produto" (azul, vermelho, verde, sem ordem entre as categorias) é convertida via label encoding em valores numéricos (0, 1, 2). Essa abordagem é sempre equivalente ao one-hot encoding do ponto de vista matemático para modelos como regressão linear, pois ambos os métodos preservam igualmente a ausência de relação de ordem entre as categorias.

Gabarito:
I .. 20 - C
A .. J - Verdadeiro
I .. T - Falso