AULA 18 · EXERCÍCIO GUIADO

Treinando uma rede na mão

Simpsons × Family Guy · 2 iterações, passo a passo

O PROBLEMA

Quem é quem?

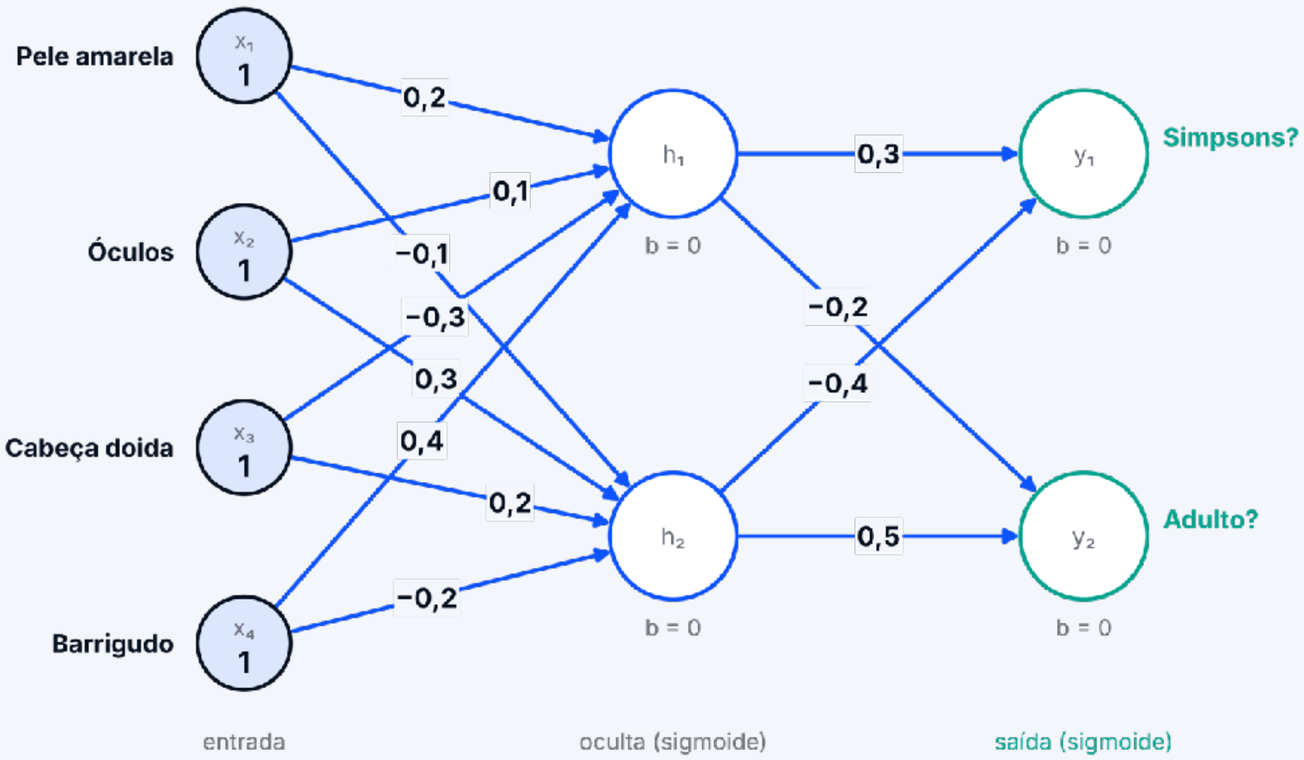
Personagem	Pele amarela	Óculos	Cabeça doida	Barrigudo	Simpsons?	Adulto?
Homer	1	0	0	1	1	1
Bart	1	0	1	0	1	0
Peter	0	1	0	1	0	1
Stewie	0	0	1	0	0	0

Cada característica vale **1** (tem) ou **0** (não tem). As saídas também: 1 = sim, 0 = não.

A rede precisa decorar a tabela: ao ver as 4 características, acertar as duas respostas.

A REDE

Arquitetura 4 - 2 - 2



FICHA TÉCNICA

4 entradas: as características

2 neurônios ocultos: h_1 e h_2

2 saídas: Simpsons? e Adulto?

Ativação: $\sigma(z) = 1 / (1 + e^{-z})$

Erro: $E = \frac{1}{2} \cdot \Sigma (t - y)^2$

Taxa de aprendizado: $\eta = 2$

Pesos iniciais: chutados (azul).

Biases (b): começam em 0.

Cada seta carrega um peso. Treinar é ajustar esses 12 pesos + 4 biases.

A RECEITA

Uma iteração em 8 passos

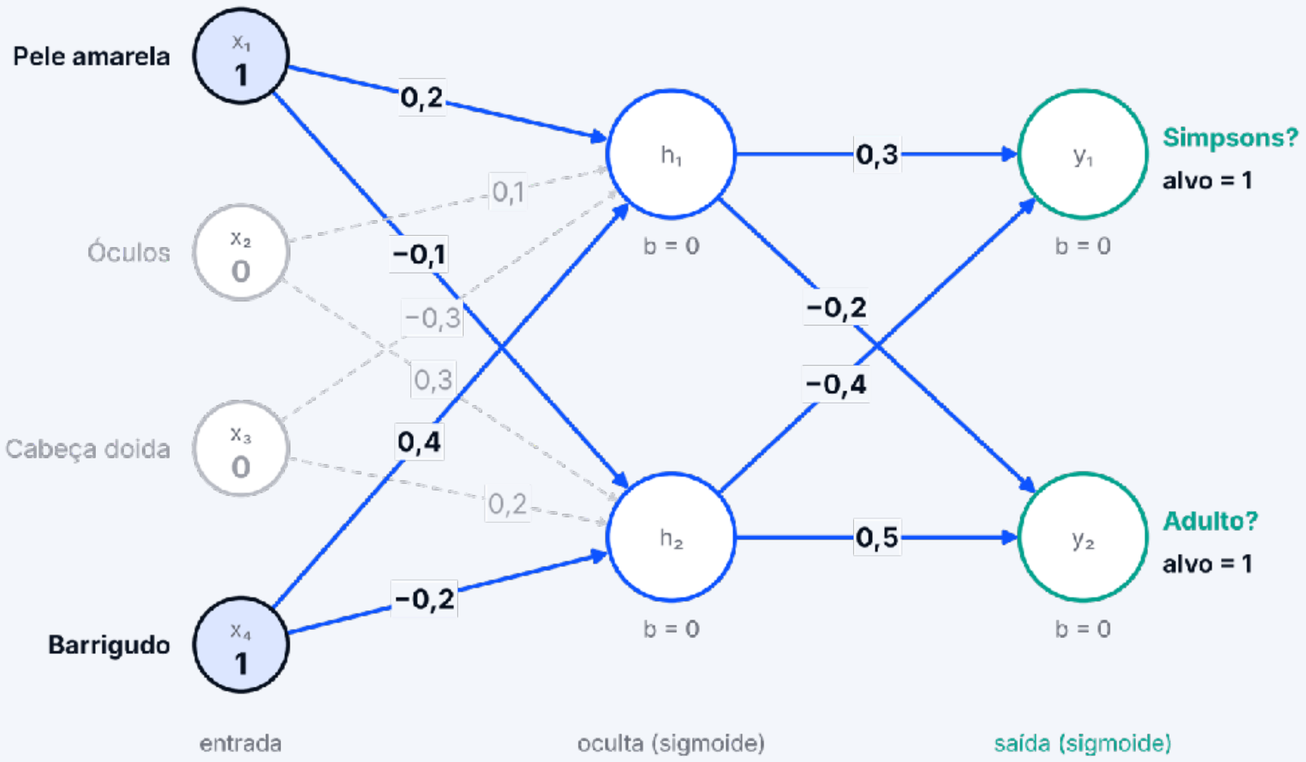
Passo	Conta	Em português
1	$z = x \cdot W + b$; $h = \sigma(z)$	forward: camada oculta
2	$zo = h \cdot V + b$; $y = \sigma(zo)$	forward: camada de saída
3	$E = \frac{1}{2} \Sigma (t - y)^2$	mede o erro
4	$\delta = (y - t) \cdot y(1-y)$	culpa da saída
5	$\partial E/\partial v = \delta \cdot h$	gradientes de saída
6	$\delta = h(1-h) \cdot \Sigma\, \delta_saída \cdot v$	culpa volta pros ocultos
7	$\partial E/\partial w = \delta \cdot x$	gradientes de entrada
8	$novo = antigo - \eta \cdot grad$	atualiza tudo

01

Iteração 1: Homer

x = (1, 0, 0, 1) · alvo = (1, 1)

Passo 0: Homer entra em cena



PONTO DE PARTIDA

Entrada: x = (1, 0, 0, 1)

Ligados: pele amarela, barrigudo.

Alvo: t = (1, 1)

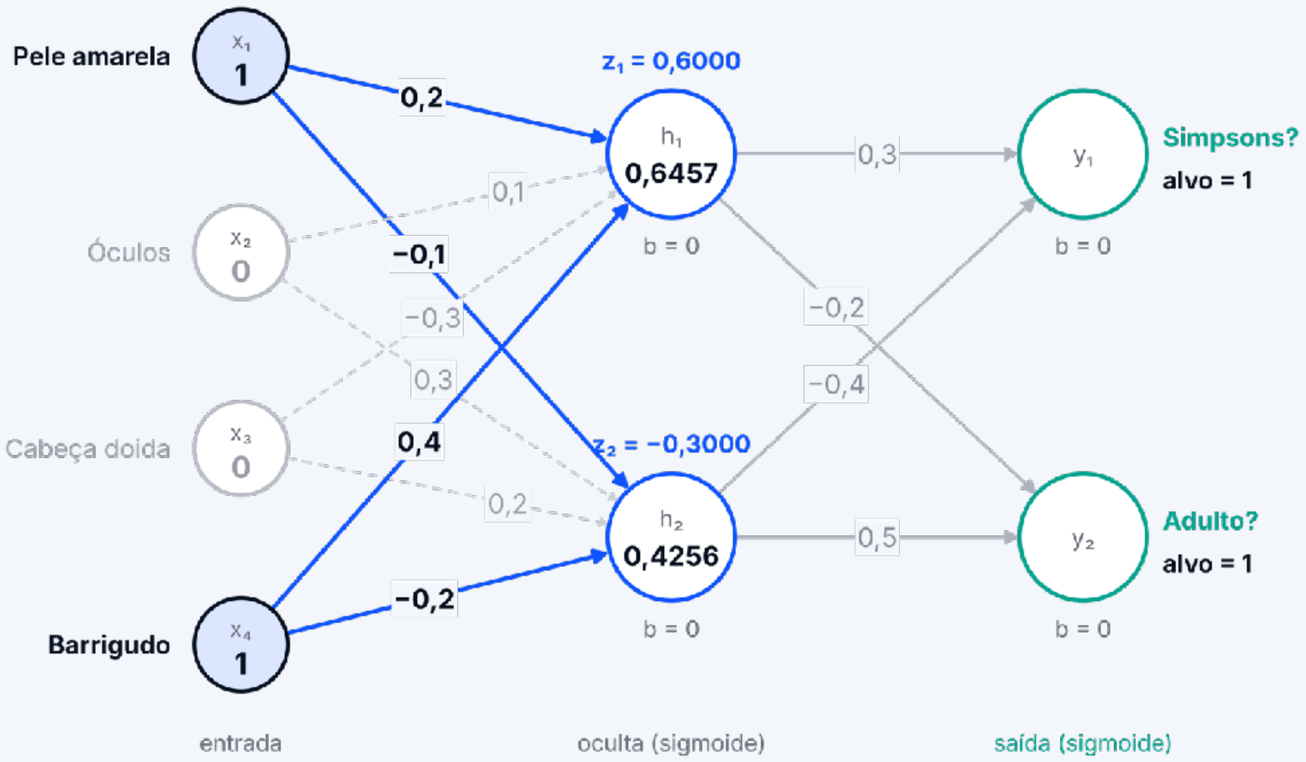
→ é dos Simpsons e é adulto.

Rede: pesos chutados, biases = 0.

Entradas = 0 (cinza) não participam: 0 × peso = 0.

Ainda não calculamos nada. Só olhe o desenho: é o "retrato" da rede.

Passo 1: forward, camada oculta



FORWARD · NEURÔNIOS OCULTOS

$z = (\text{entradas} \times \text{pesos}) + \text{bias}$

$z_1 = 1 \cdot 0{,}2 + 1 \cdot 0{,}4 + 0 = \mathbf{0{,}6000}$

$z_2 = 1 \cdot (-0{,}1) + 1 \cdot (-0{,}2) + 0 = \mathbf{-0{,}3000}$

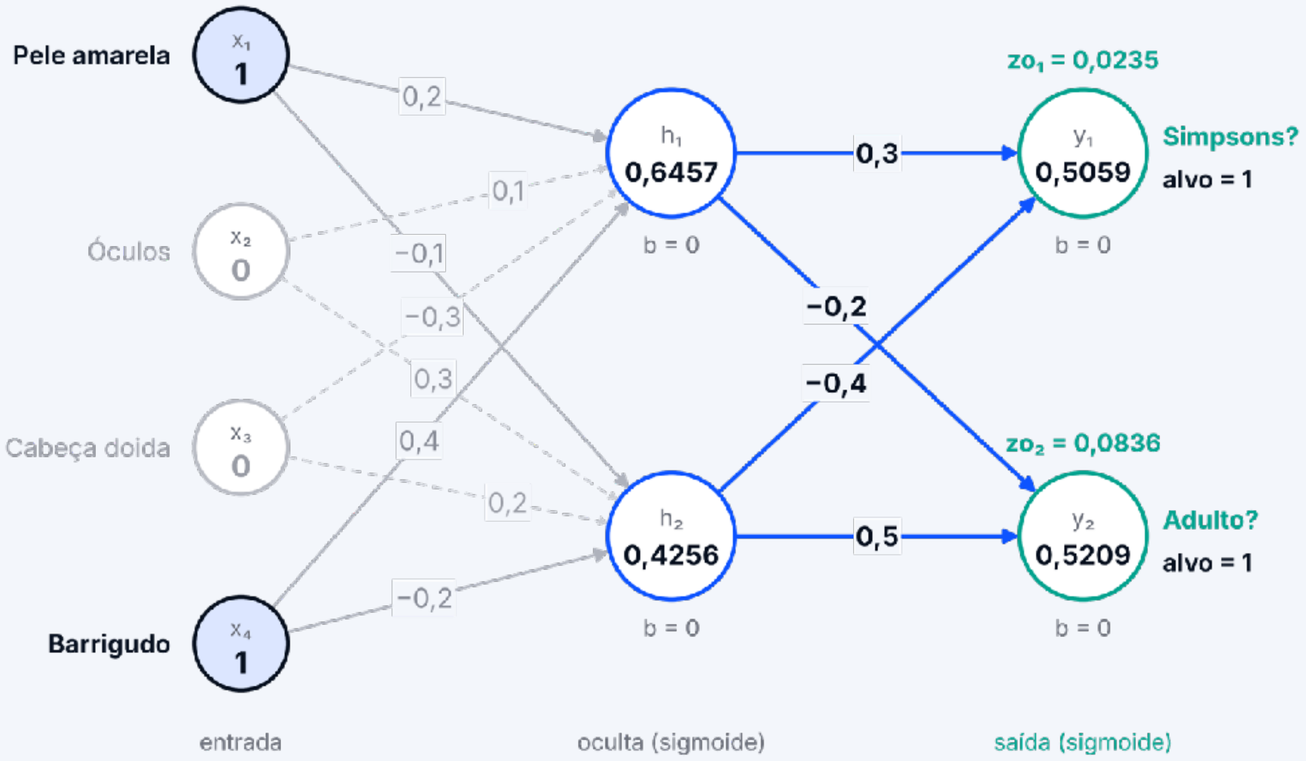
$h = \sigma(z) = 1 / (1 + e^{-z})$

$h_1 = 1/(1 + 0{,}5488) = 1/1{,}5488 = \mathbf{0{,}6457}$

$h_2 = 1/(1 + 1{,}3499) = 1/2{,}3499 = \mathbf{0{,}4256}$

Só as entradas ligadas (=1) entram na soma. A sigmoide amassa z para o intervalo 0–1.

Passo 2: forward, camada de saída



FORWARD · NEURÔNIOS DE SAÍDA

zo = (h × pesos de saída) + bias

$zo_1 = 0{,}6457 \cdot 0{,}3 + 0{,}4256 \cdot (-0{,}4) + 0 =$ **0,0235**

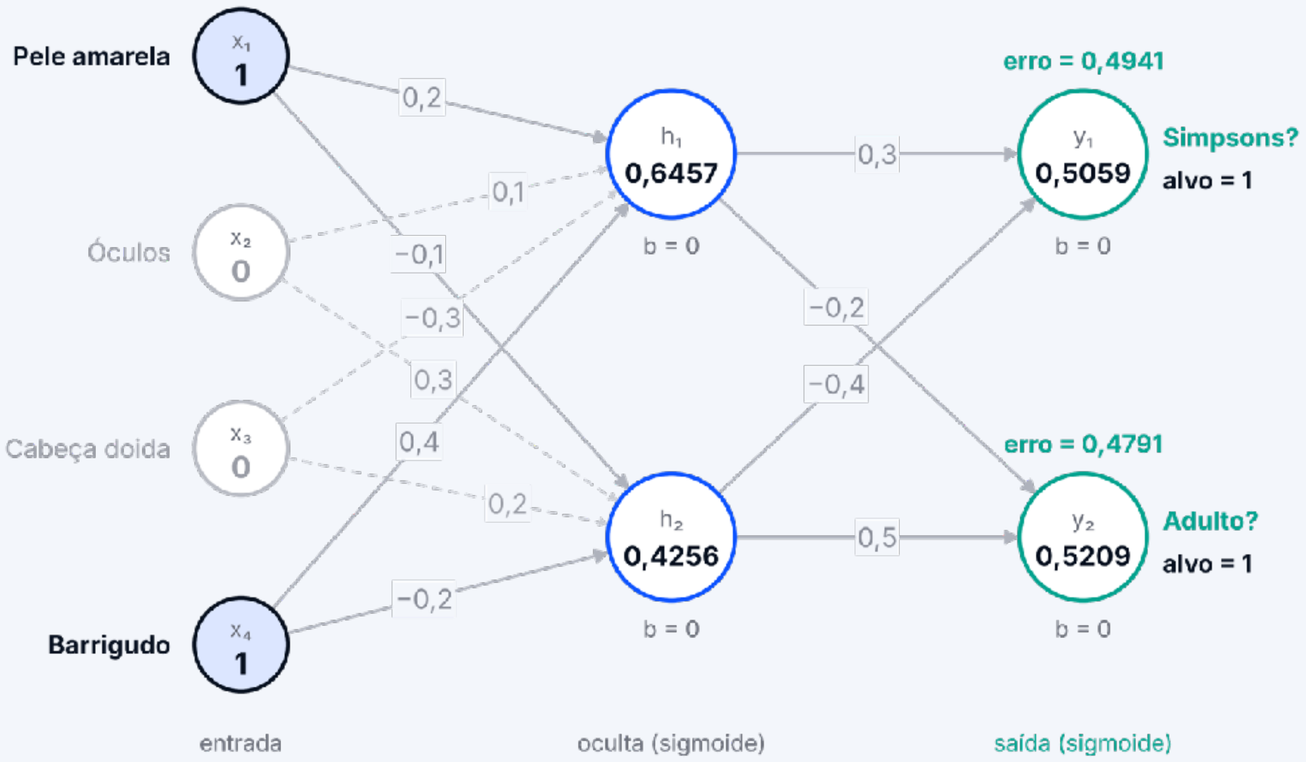
$zo_2 = 0{,}6457 \cdot (-0{,}2) + 0{,}4256 \cdot 0{,}5 + 0 =$ **0,0836**

$y_1 = 1/(1 + 0{,}9768) =$ **0,5059**

$y_2 = 1/(1 + 0{,}9198) =$ **0,5209**

A rede respondeu ~0,5 pra tudo: está na dúvida, cara ou coroa. Esperado: nunca viu nada ainda.

Passo 3: o tamanho do erro



ERRO DA REDE

erro de cada saída: e = t − y

$e_1 = 1 - 0{,}5059 = \mathbf{0{,}4941}$

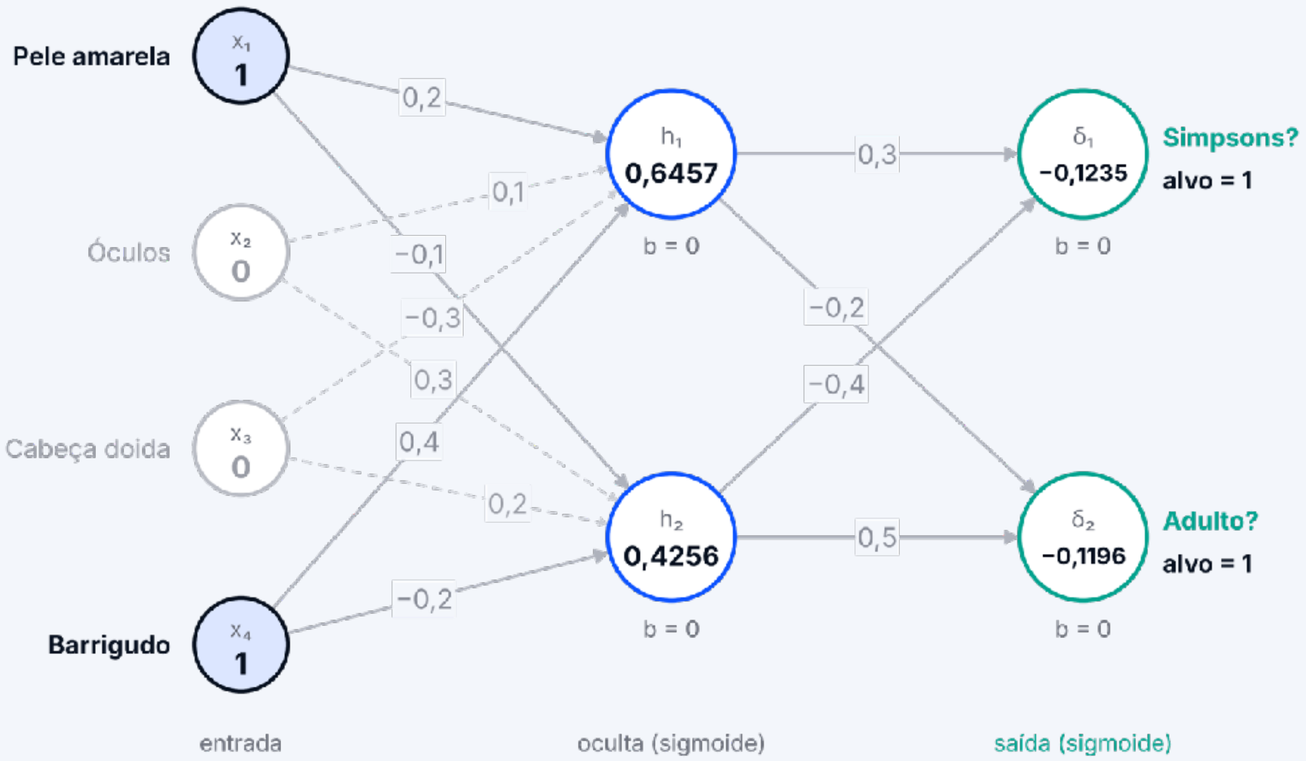
$e_2 = 1 - 0{,}5209 = \mathbf{0{,}4791}$

$E = \frac{1}{2} \cdot (e_1^2 + e_2^2)$

$E = \frac{1}{2} \cdot (0{,}2442 + 0{,}2295) = \mathbf{0{,}2369}$

E é o "tamanho da vergonha". Treinar = empurrar E pra perto de 0, um passinho por vez.

Passo 4: δ da camada de saída



BACKPROP · CULPA DA SAÍDA

δ de saída = (y − t) · y · (1 − y)

(y·(1−y) é a derivada da sigmoide)

$y_1(1-y_1) = 0{,}5059 \cdot 0{,}4941 = 0{,}2500$

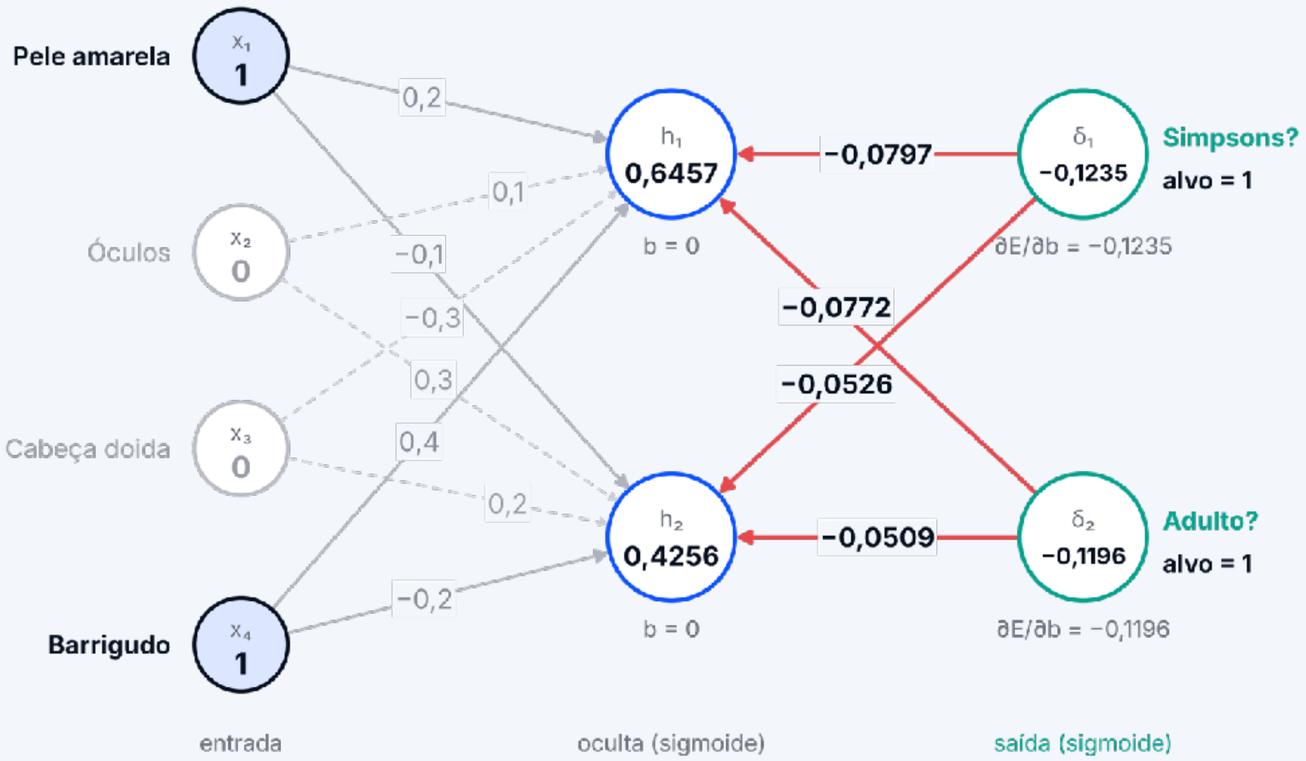
$\delta_1 = (-0{,}4941) \cdot 0{,}2500 = \mathbf{-0{,}1235}$

$y_2(1-y_2) = 0{,}5209 \cdot 0{,}4791 = 0{,}2496$

$\delta_2 = (-0{,}4791) \cdot 0{,}2496 = \mathbf{-0{,}1196}$

δ negativo = "essa saída precisa SUBIR". Os dois δ saíram negativos: a rede quer aumentar as duas saídas.

Passo 5: gradientes dos pesos de saída



BACKPROP · GRADIENTES (SAÍDA)

∂E/∂v = δ da saída × h de onde vem

v_{11}: −0,1235·0,6457 = **−0,0797**

v_{12}: −0,1196·0,6457 = **−0,0772**

v_{21}: −0,1235·0,4256 = **−0,0526**

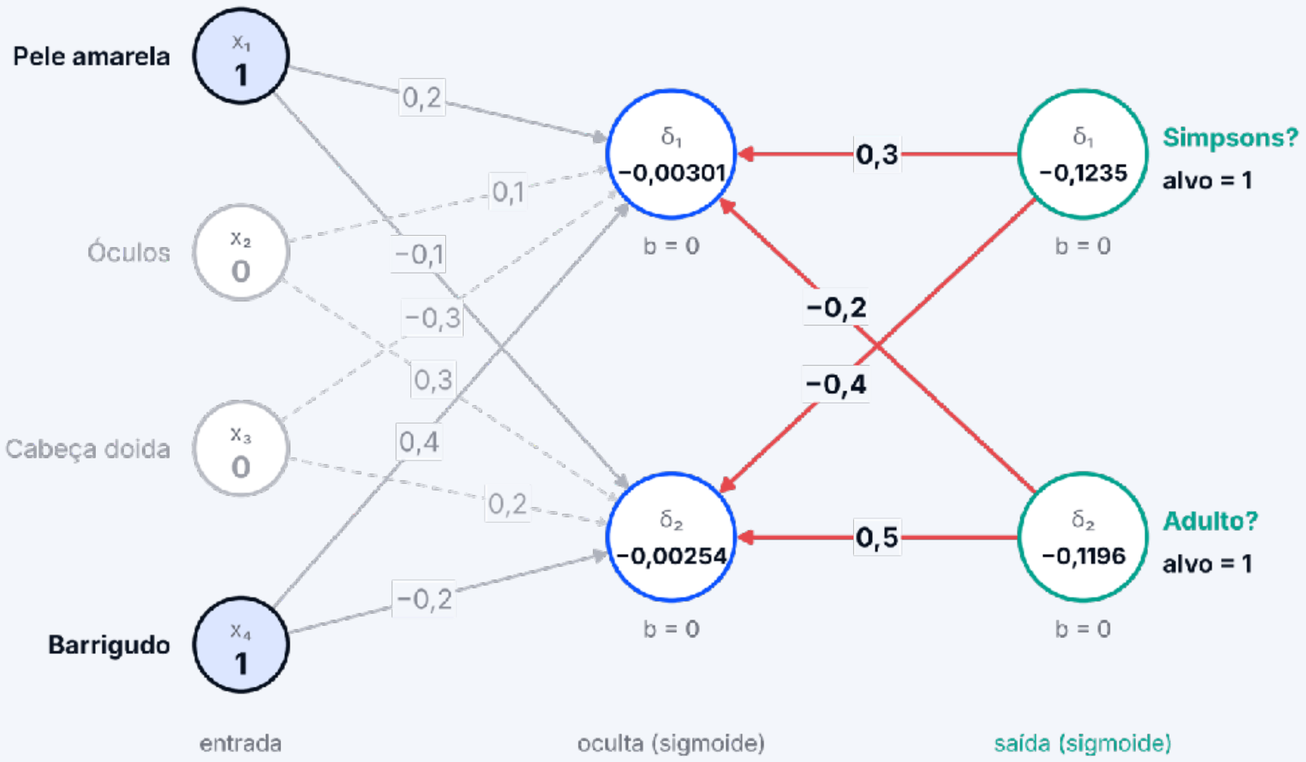
v_{22}: −0,1196·0,4256 = **−0,0509**

Bias: ∂E/∂b = δ

b_1: **−0,1235** b_2: **−0,1196**

Gradiente = "quanto o erro muda se eu mexer neste peso". Quem mais contribuiu leva mais ajuste.

Passo 6: δ da camada oculta (a volta)



BACKPROP · CULPA DOS OCULTOS

S = Σ δ_saída × peso ANTIGO

δ_oculto = h·(1−h) · S

$S_1 = (-0{,}1235)\cdot 0{,}3$
$\quad + (-0{,}1196)\cdot(-0{,}2) = -0{,}01314$

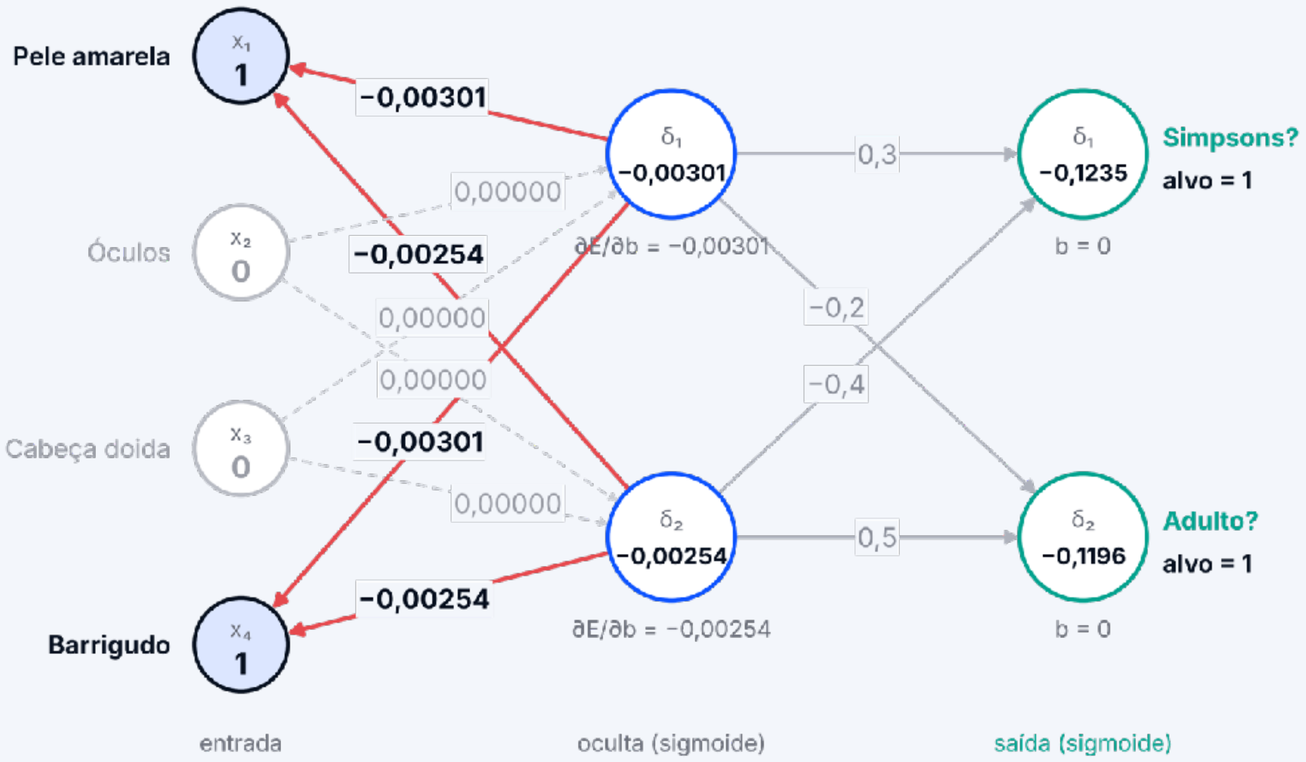
$\delta_1 = 0{,}2288\cdot(-0{,}01314) = \mathbf{-0{,}00301}$

$S_2 = (-0{,}1235)\cdot(-0{,}4)$
$\quad + (-0{,}1196)\cdot 0{,}5 = -0{,}01038$

$\delta_2 = 0{,}2445\cdot(-0{,}01038) = \mathbf{-0{,}00254}$

Use os pesos de saída ANTES da atualização (pegadinha clássica).

Passo 7: gradientes dos pesos da entrada



BACKPROP · GRADIENTES (OCULTA)

$\partial E/\partial w = \delta$ do oculto × x da entrada

w_{11}: −0,00301·1 = **−0,00301**

w_{12}: −0,00254·1 = **−0,00254**

w_{41}: −0,00301·1 = **−0,00301**

w_{42}: −0,00254·1 = **−0,00254**

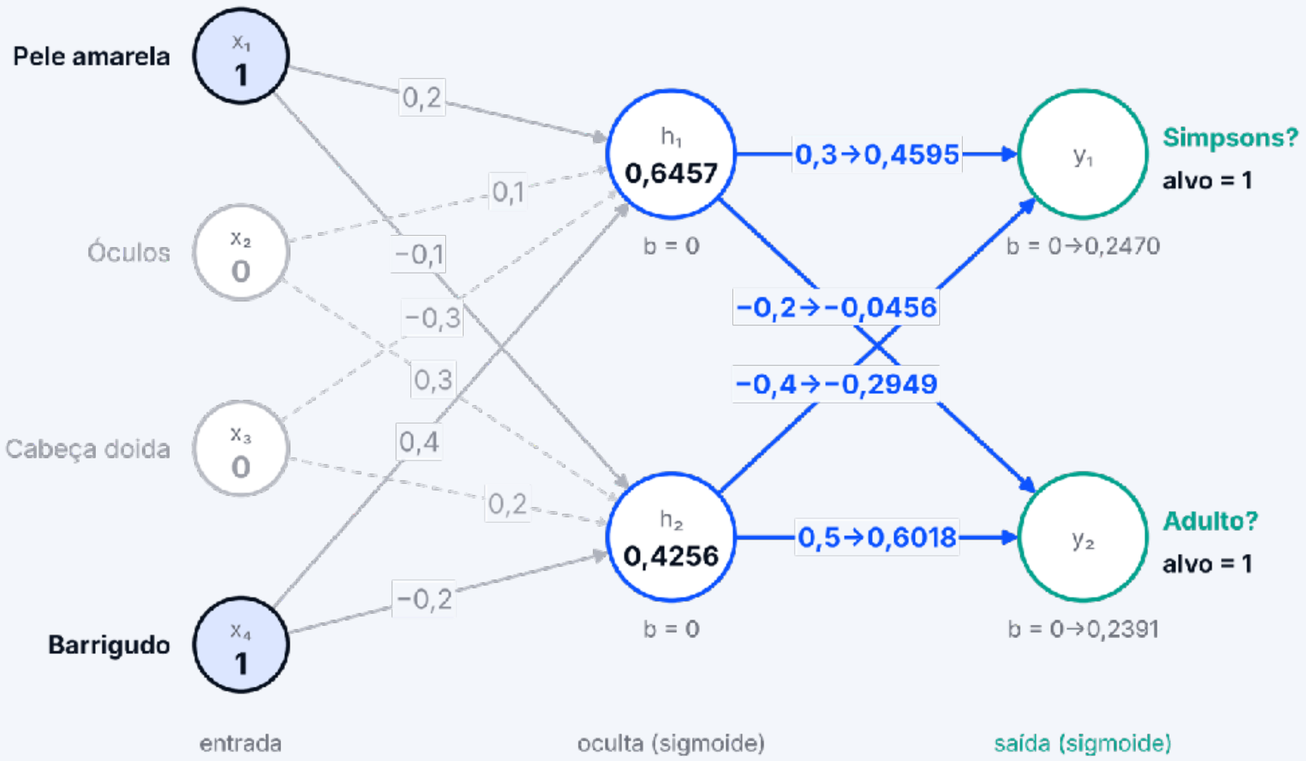
Entradas x_2 e x_3 = 0 → gradiente 0.

Bias: b_1 = **−0,00301**, b_2 = **−0,00254**

Entrada desligada = peso "dorme": quem não participou não é culpado nem premiado.

ITERAÇÃO 1 · HOMER

Passo 8a: atualizar pesos de saída



ATUALIZAÇÃO · CAMADA DE SAÍDA

novo = antigo − η · gradiente (η = 2)

v_{11}: 0,3 − 2·(−0,0797) = **0,4595**

v_{12}: −0,2 − 2·(−0,0772) = **−0,0456**

v_{21}: −0,4 − 2·(−0,0526) = **−0,2949**

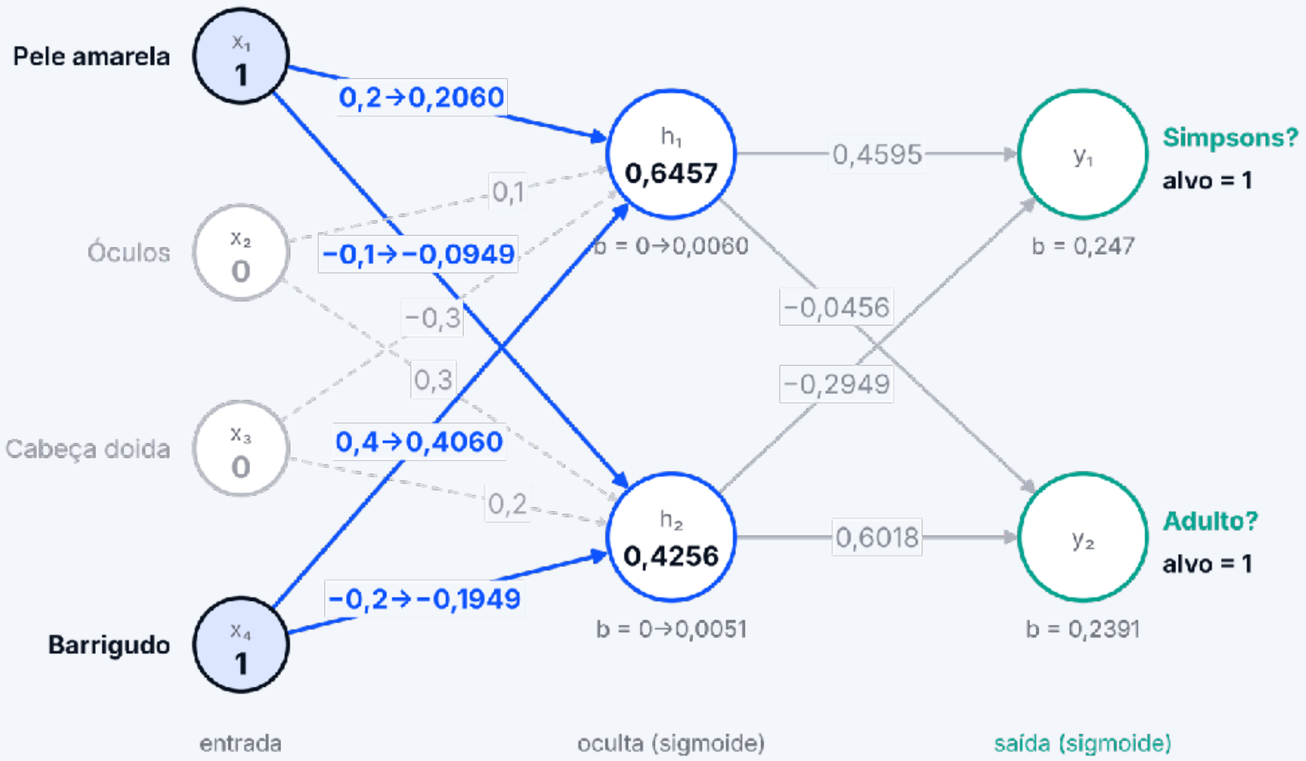
v_{22}: 0,5 − 2·(−0,0509) = **0,6018**

b_1: 0 − 2·(−0,1235) = **0,2470**

b_2: 0 − 2·(−0,1196) = **0,2391**

Sinal do gradiente negativo → o peso SOBE. Positivo → o peso DESCE. η = 2 é o tamanho do passo.

Passo 8b: atualizar pesos da entrada



ATUALIZAÇÃO · CAMADA OCULTA

novo = antigo − η · gradiente (η = 2)

w_{11}: 0,2 − 2·(−0,00301) = **0,2060**

w_{12}: −0,1 − 2·(−0,00254) = **−0,0949**

w_{41}: 0,4 − 2·(−0,00301) = **0,4060**

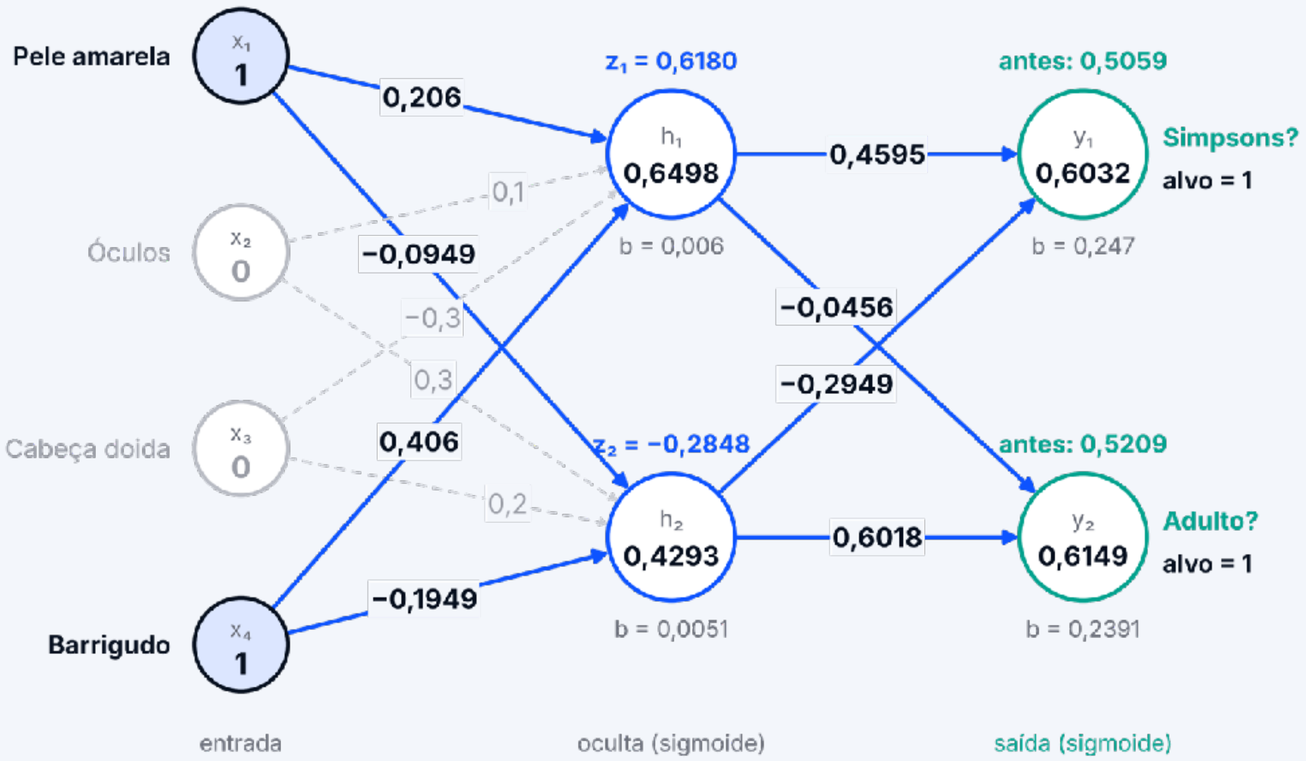
w_{42}: −0,2 − 2·(−0,00254) = **−0,1949**

b_1: 0 − 2·(−0,00301) = **0,0060**

b_2: 0 − 2·(−0,00254) = **0,0051**

Entradas zeradas: pesos iguais. Mudança pequena: a culpa chega diluída.

Passo 9: a rede depois do treino



RESULTADO DA ITERAÇÃO

Rodando o forward de novo, com a rede nova:

y_1: 0,5059 → **0,6032** (alvo 1)

y_2: 0,5209 → **0,6149** (alvo 1)

E: 0,2369 → **0,1529**

(o erro caiu 35%)

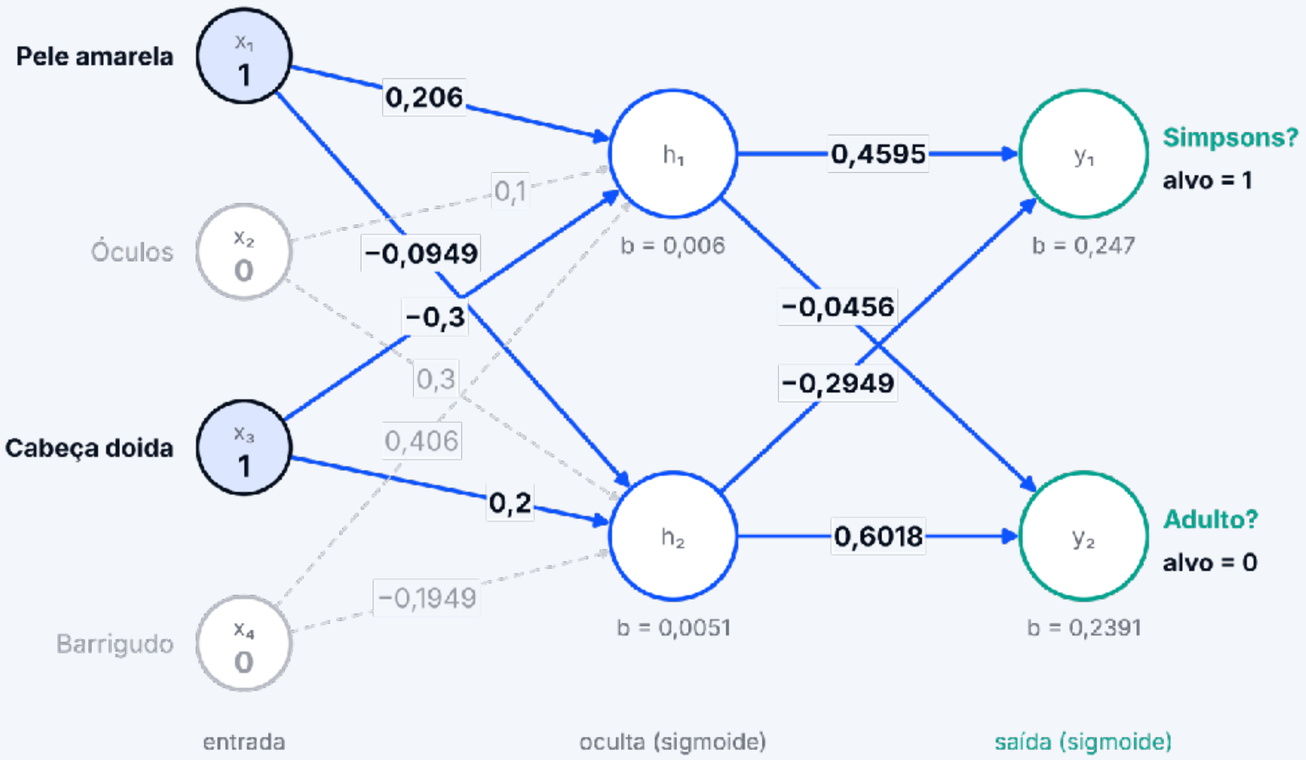
Um passinho só e as duas saídas já foram na direção do alvo 1. Agora esse retrato vira o ponto de partida do Bart.

02

Iteração 2: Bart

x = (1, 0, 1, 0) · alvo = (1, 0)

Passo 0: Bart entra em cena



PONTO DE PARTIDA

Entrada: x = (1, 0, 1, 0)

Ligados: pele amarela, cabeça doida.

Alvo: t = (1, 0)

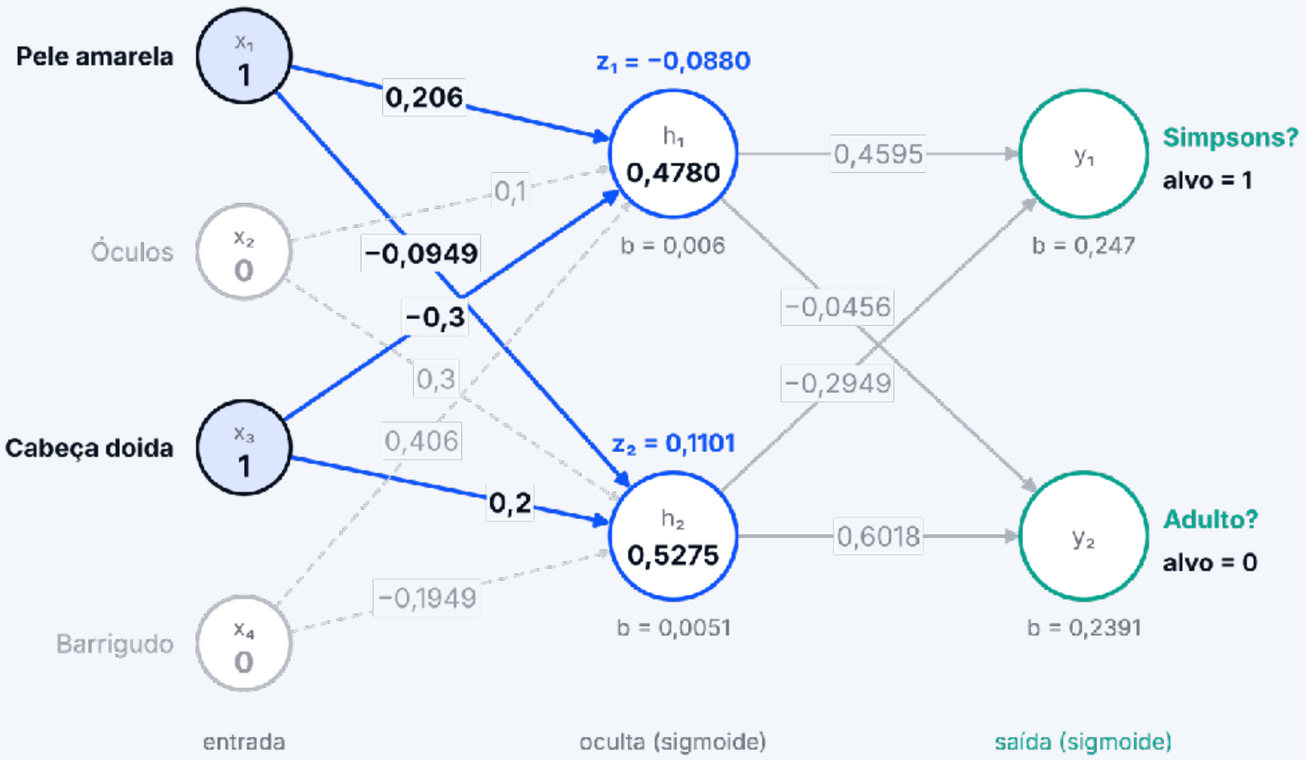
→ é dos Simpsons e é criança.

Rede: pesos que sobraram da iteração 1; biases já mexidos.

Entradas = 0 (cinza) não participam: 0 × peso = 0.

Ainda não calculamos nada. Só olhe o desenho: é o "retrato" da rede.

Passo 1: forward, camada oculta



FORWARD · NEURÔNIOS OCULTOS

z = (entradas × pesos) + bias

$z_1 = 1 \cdot 0{,}206 + 1 \cdot (-0{,}3) + 0{,}006 = \mathbf{-0{,}0880}$

$z_2 = 1 \cdot (-0{,}0949) + 1 \cdot 0{,}2 + 0{,}0051 = \mathbf{0{,}1101}$

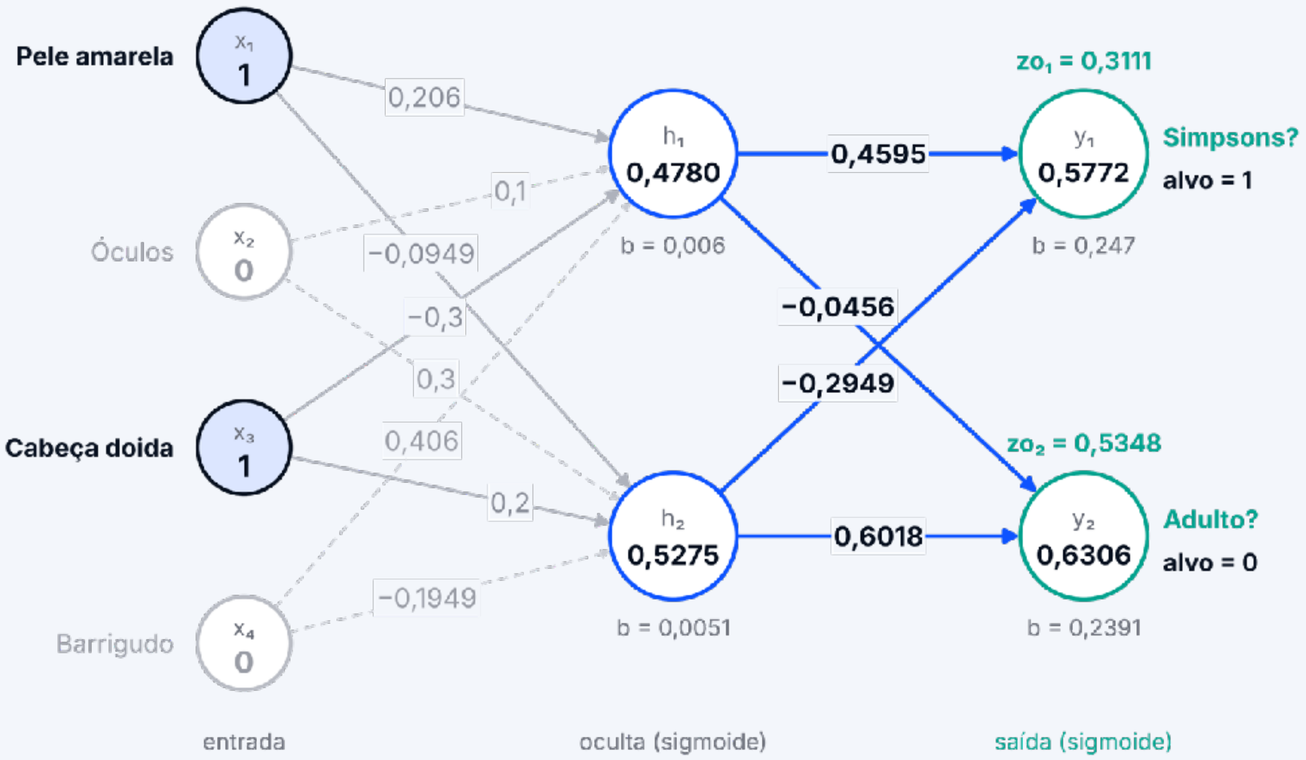
h = σ(z) = 1 / (1 + e^−z)

$h_1 = 1/(1 + 1{,}0920) = 1/2{,}0920 = \mathbf{0{,}4780}$

$h_2 = 1/(1 + 0{,}8957) = 1/1{,}8957 = \mathbf{0{,}5275}$

Só as entradas ligadas (=1) entram na soma. A sigmoide amassa z para o intervalo 0–1.

Passo 2: forward, camada de saída



FORWARD · NEURÔNIOS DE SAÍDA

zo = (h × pesos de saída) + bias

zo_1 = 0,4780·0,4595 + 0,5275·(−0,2949) + 0,247 = **0,3111**

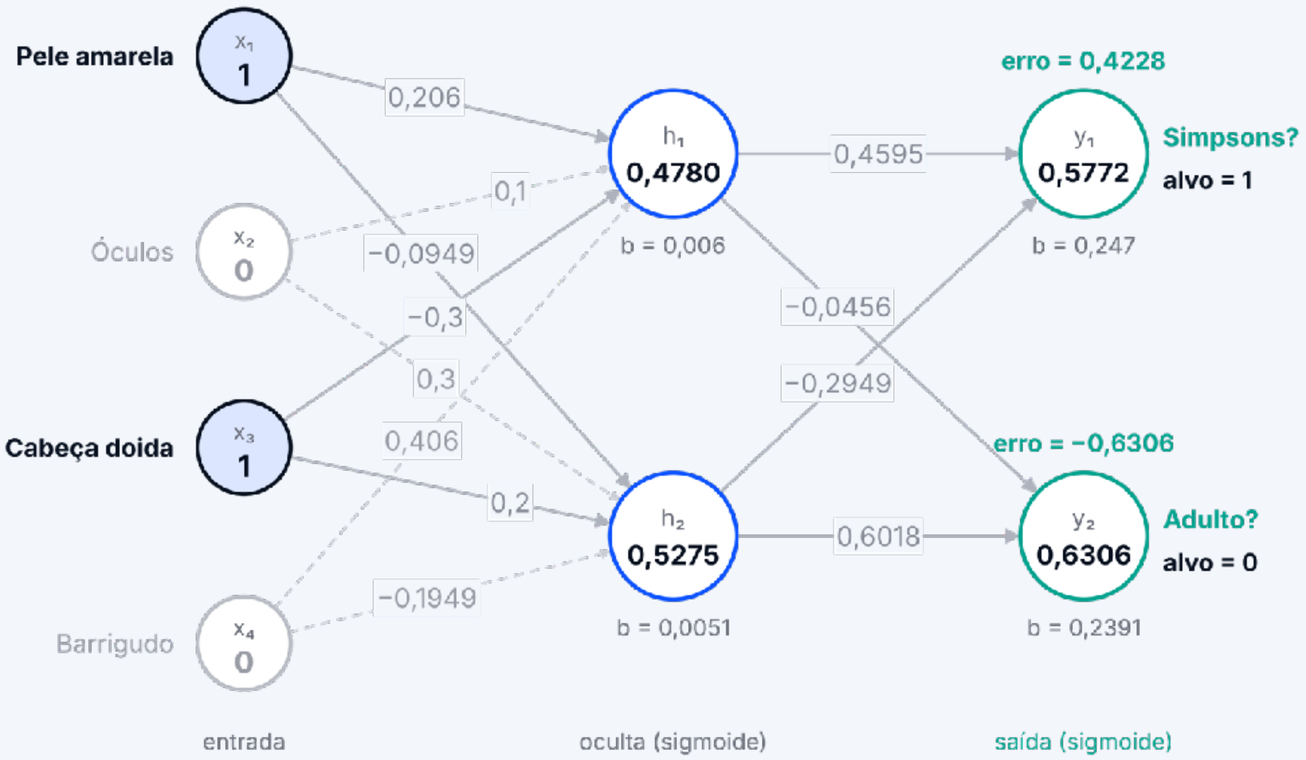
zo_2 = 0,4780·(−0,0456) + 0,5275·0,6018 + 0,2391 = **0,5348**

y_1 = 1/(1 + 0,7326) = **0,5772**

y_2 = 1/(1 + 0,5858) = **0,6306**

Já não é mais 0,5 pra tudo: o treino do Homer deixou marcas. Ainda erra, mas menos.

Passo 3: o tamanho do erro



ERRO DA REDE

erro de cada saída: $e = t - y$

$e_1 = 1 - 0{,}5772 = \mathbf{0{,}4228}$

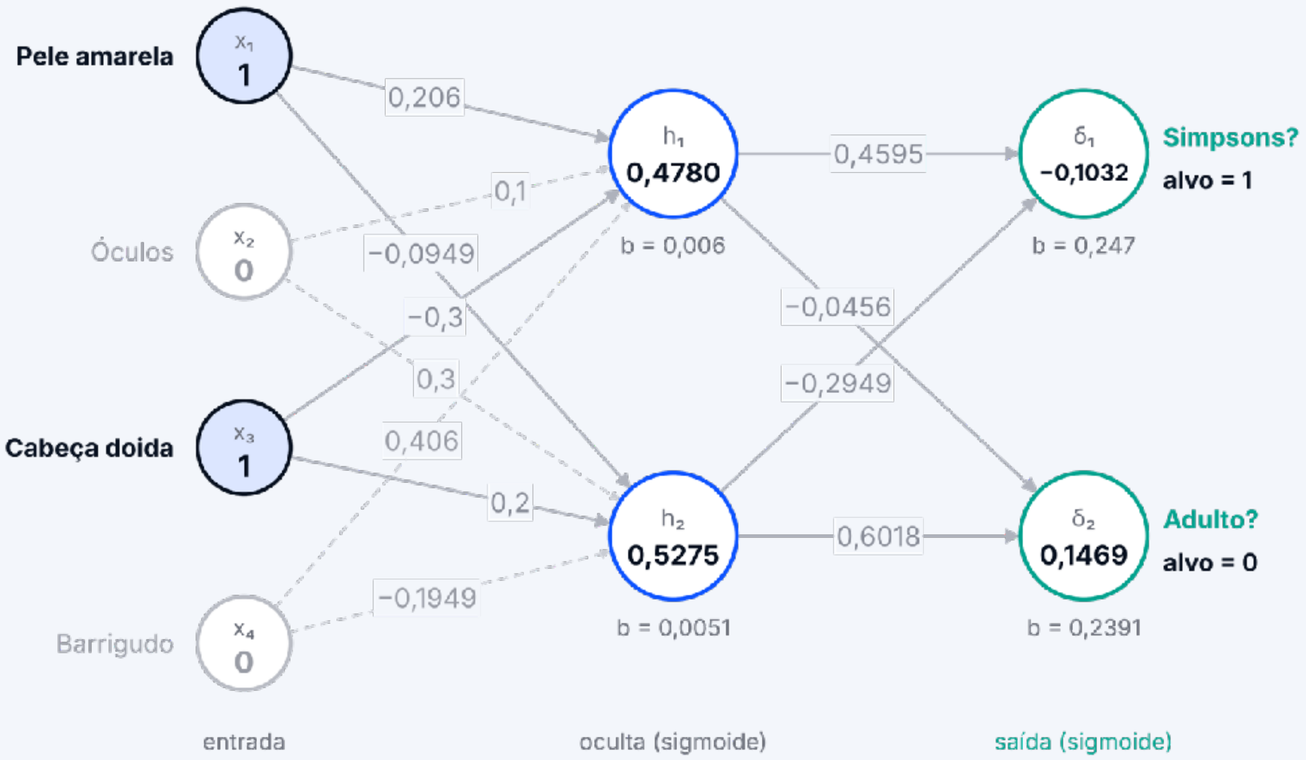
$e_2 = 0 - 0{,}6306 = \mathbf{-0{,}6306}$

$E = \frac{1}{2} \cdot (e_1^2 + e_2^2)$

$E = \frac{1}{2} \cdot (0{,}1788 + 0{,}3976) = \mathbf{0{,}2882}$

E é o "tamanho da vergonha". Treinar = empurrar E pra perto de 0, um passinho por vez.

Passo 4: δ da camada de saída



BACKPROP · CULPA DA SAÍDA

δ de saída = (y − t) · y · (1 − y)

(y·(1−y) é a derivada da sigmoide)

$y_1(1-y_1) = 0{,}5772 \cdot 0{,}4228 = 0{,}2440$

$\delta_1 = (-0{,}4228) \cdot 0{,}2440 = \mathbf{-0{,}1032}$

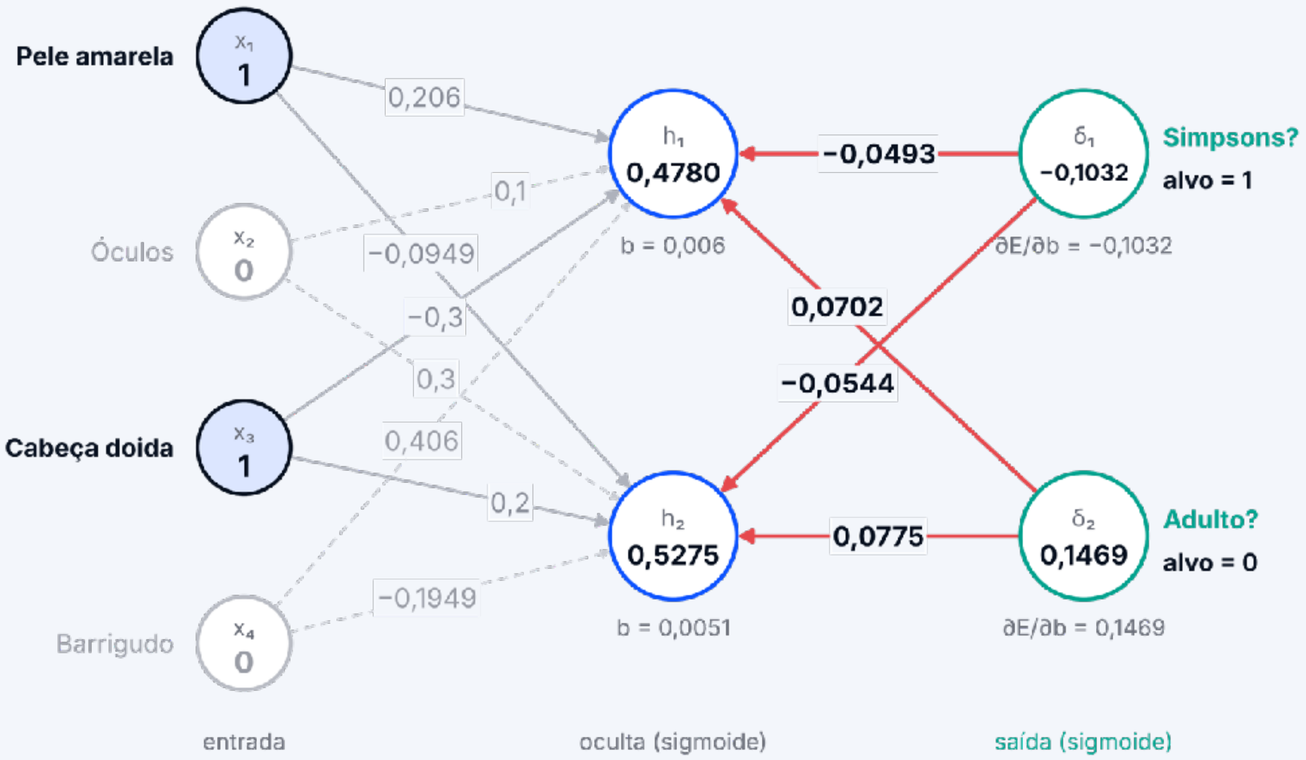
$y_2(1-y_2) = 0{,}6306 \cdot 0{,}3694 = 0{,}2329$

$\delta_2 = (0{,}6306) \cdot 0{,}2329 = \mathbf{0{,}1469}$

δ_1 negativo = "sobe!". δ_2 POSITIVO = "desce!" (alvo 0). O sinal é a bússola.

ITERAÇÃO 2 · BART

Passo 5: gradientes dos pesos de saída



BACKPROP · GRADIENTES (SAÍDA)

∂E/∂v = δ da saída × h de onde vem

v_{11}: −0,1032·0,4780 = **−0,0493**

v_{12}: 0,1469·0,4780 = **0,0702**

v_{21}: −0,1032·0,5275 = **−0,0544**

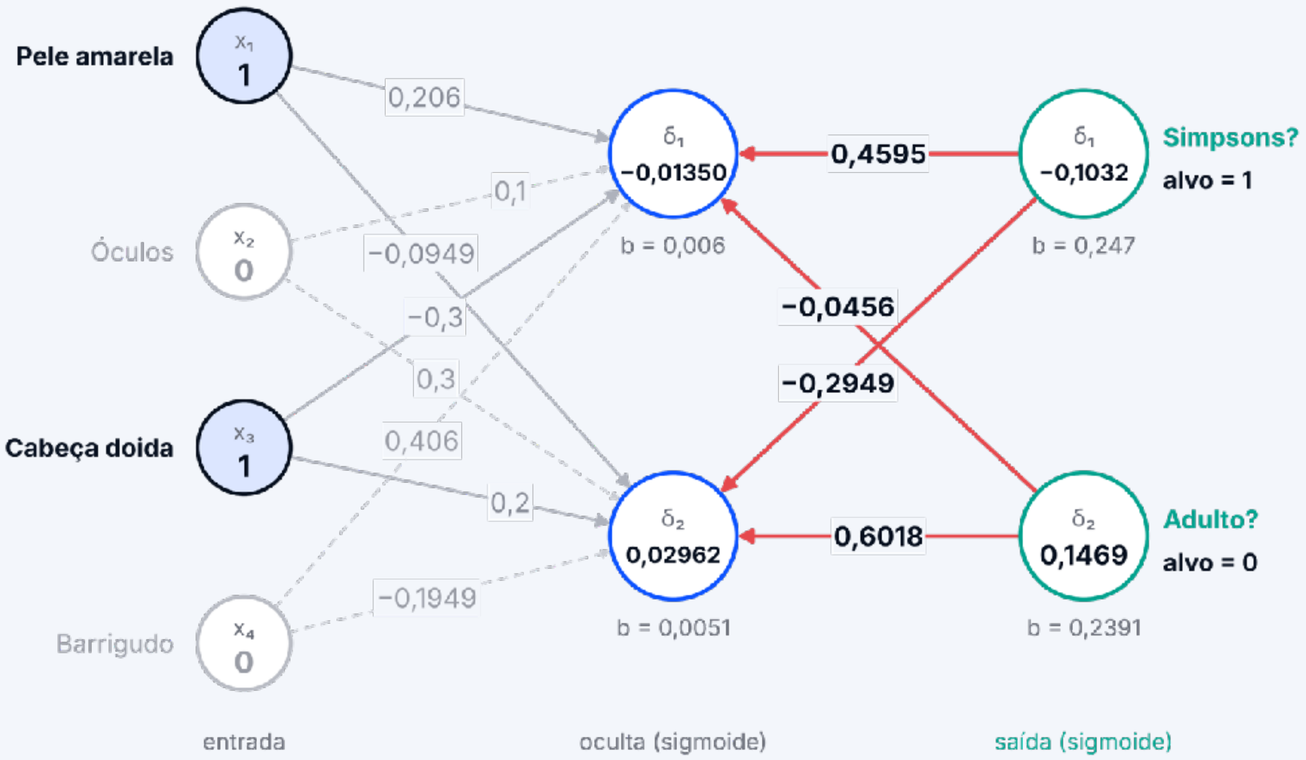
v_{22}: 0,1469·0,5275 = **0,0775**

Bias: ∂E/∂b = δ

b_1: **−0,1032** b_2: **0,1469**

Gradiente = "quanto o erro muda se eu mexer neste peso". Quem mais contribuiu leva mais ajuste.

Passo 6: δ da camada oculta (a volta)



BACKPROP · CULPA DOS OCULTOS

$S = \Sigma\ \delta_saída \times peso\ ANTIGO$

$\delta_oculto = h\cdot(1-h)\cdot S$

$S_1 = (-0{,}1032)\cdot 0{,}4595$
$\quad + (0{,}1469)\cdot(-0{,}0456) = -0{,}05412$

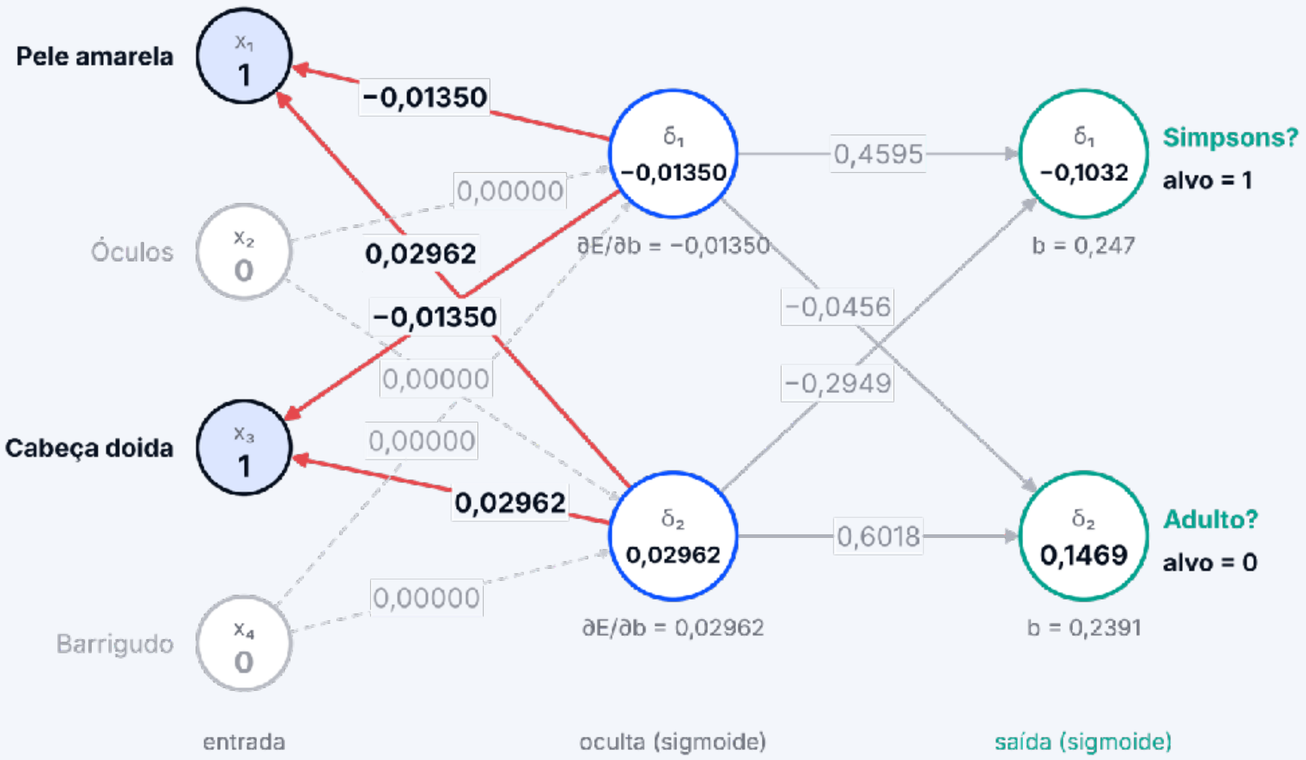
$\delta_1 = 0{,}2495\cdot(-0{,}05412) = \mathbf{-0{,}01350}$

$S_2 = (-0{,}1032)\cdot(-0{,}2949)$
$\quad + (0{,}1469)\cdot 0{,}6018 = 0{,}11882$

$\delta_2 = 0{,}2492\cdot(0{,}11882) = \mathbf{0{,}02962}$

Use os pesos de saída ANTES da atualização (pegadinha clássica).

Passo 7: gradientes dos pesos da entrada



BACKPROP · GRADIENTES (OCULTA)

$\partial E/\partial w = \delta$ do oculto × x da entrada

w_{11}: −0,01350·1 = **−0,01350**

w_{12}: 0,02962·1 = **0,02962**

w_{31}: −0,01350·1 = **−0,01350**

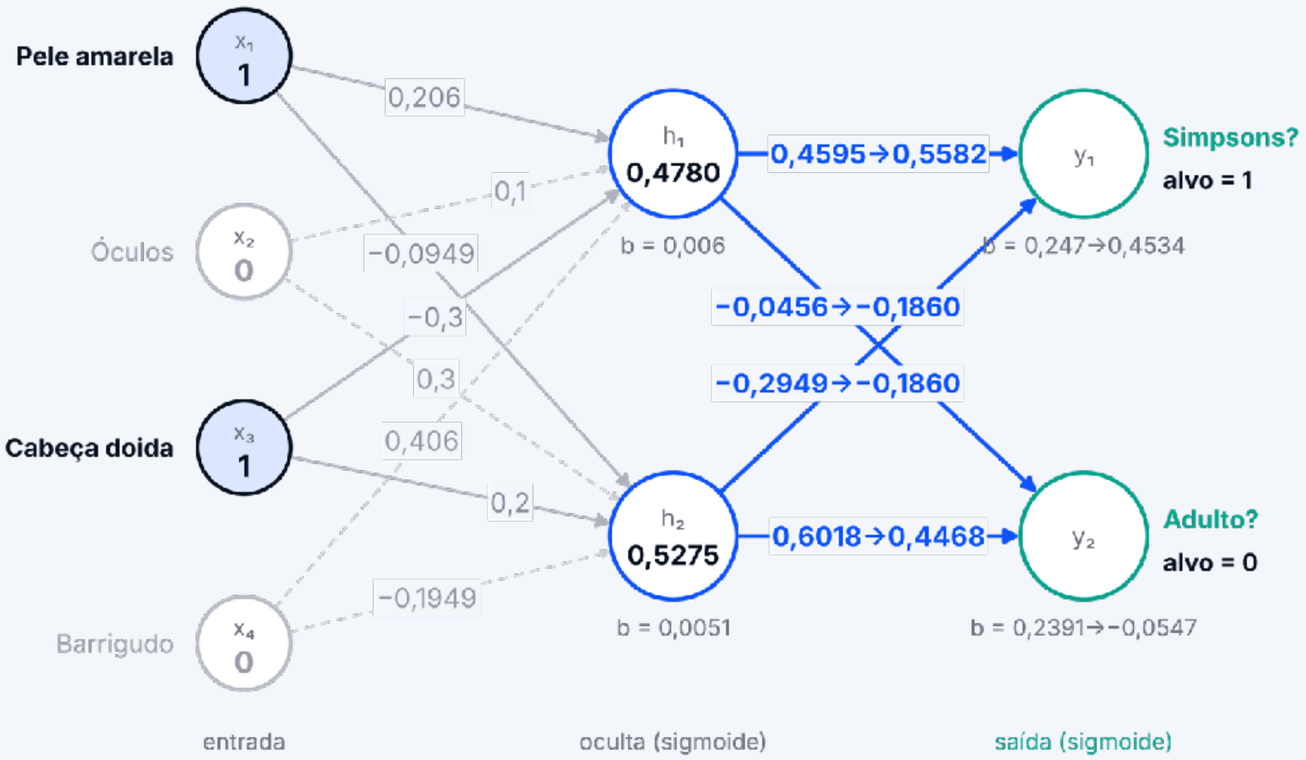
w_{32}: 0,02962·1 = **0,02962**

Entradas x_2 e x_4 = 0 → gradiente 0.

Bias: b_1 = **−0,01350**, b_2 = **0,02962**

Entrada desligada = peso "dorme": quem não participou não é culpado nem premiado.

Passo 8a: atualizar pesos de saída



ATUALIZAÇÃO · CAMADA DE SAÍDA

novo = antigo − η · gradiente (η = 2)

v_{11}: 0,4595 − 2·(−0,0493) = **0,5582**

v_{12}: −0,0456 − 2·(0,0702) = **−0,1860**

v_{21}: −0,2949 − 2·(−0,0544) = **−0,1860**

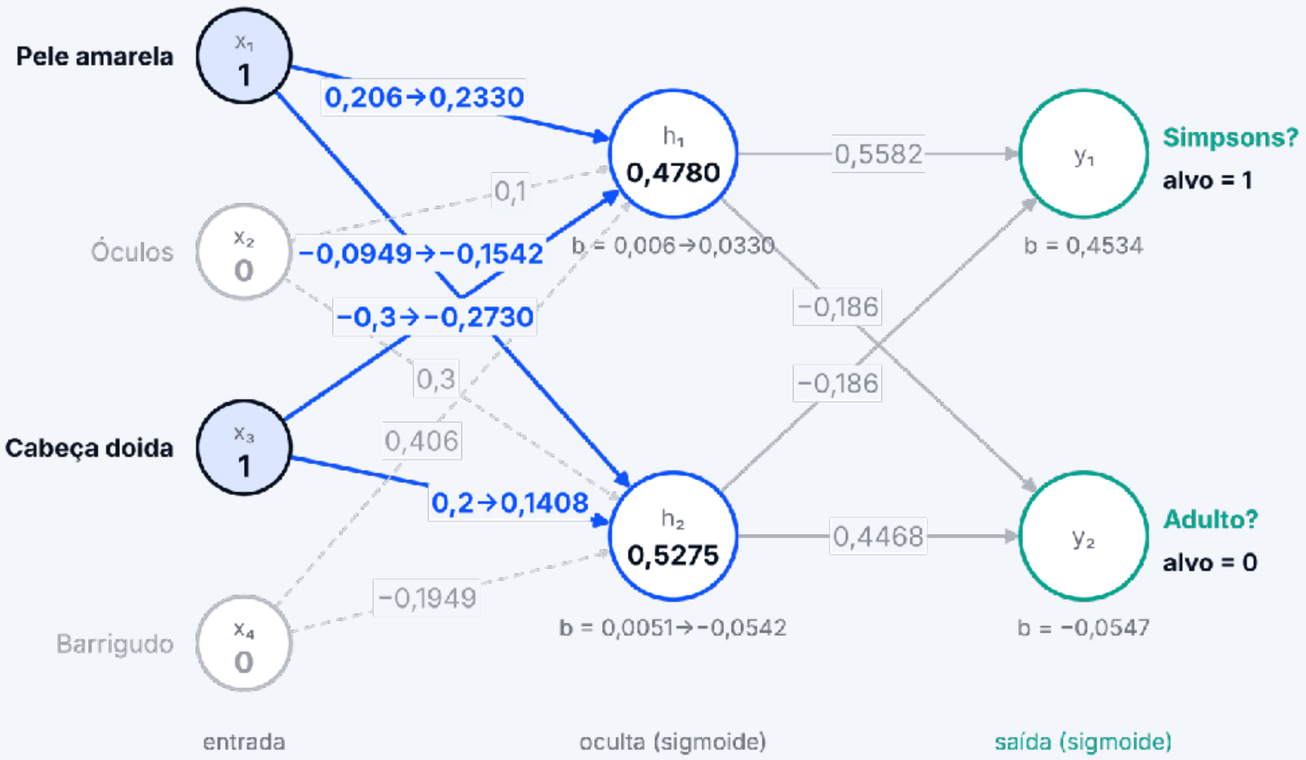
v_{22}: 0,6018 − 2·(0,0775) = **0,4468**

b_1: 0,247 − 2·(−0,1032) = **0,4534**

b_2: 0,2391 − 2·(0,1469) = **−0,0547**

Sinal do gradiente negativo → o peso SOBE. Positivo → o peso DESCE. η = 2 é o tamanho do passo.

Passo 8b: atualizar pesos da entrada



ATUALIZAÇÃO · CAMADA OCULTA

novo = antigo − η · gradiente (η = 2)

w_{11}: 0,206 − 2·(−0,01350) = **0,2330**

w_{12}: −0,0949 − 2·(0,02962) = **−0,1542**

w_{31}: −0,3 − 2·(−0,01350) = **−0,2730**

w_{32}: 0,2 − 2·(0,02962) = **0,1408**

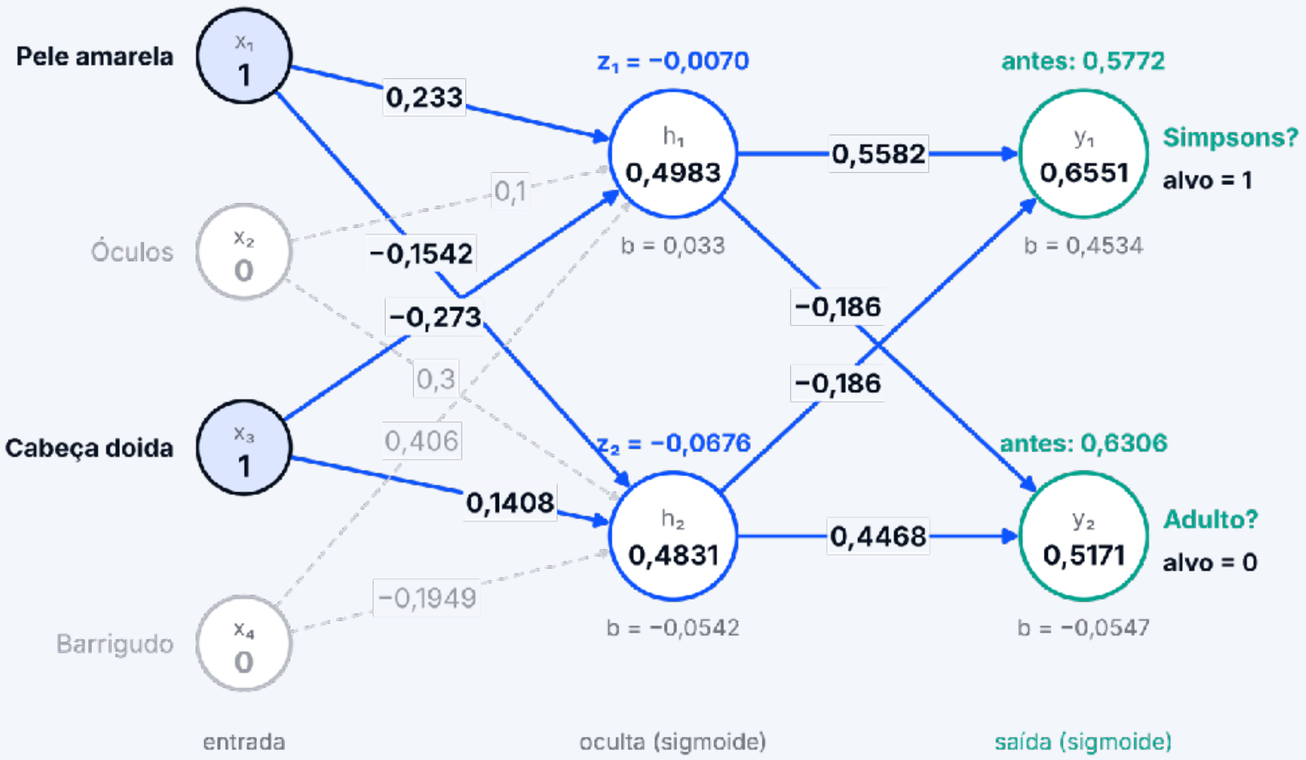
b_1: 0,006 − 2·(−0,01350) = **0,0330**

b_2: 0,0051 − 2·(0,02962) = **−0,0542**

Entradas zeradas: pesos iguais. Mudança pequena: a culpa chega diluída.

ITERAÇÃO 2 · BART

Passo 9: a rede depois do treino



RESULTADO DA ITERAÇÃO

Rodando o forward de novo, com a rede nova:

y_1: 0,5772 → **0,6551** (alvo 1)

y_2: 0,6306 → **0,5171** (alvo 0)

E: 0,2882 → **0,1932**

(o erro caiu 33%)

---

y_1 subiu (alvo 1) e y_2 desceu (alvo 0): cada saída foi pro lado certo. Vem aí uma pegadinha: o que aconteceu com o Homer?

RESUMO

Antes e depois, lado a lado

	Iteração 1 · Homer	Iteração 2 · Bart
Entrada → alvo	(1,0,0,1) → (1,1)	(1,0,1,0) → (1,0)
Saída antes	(0,5059; 0,5209)	(0,5772; 0,6306)
Saída depois	(0,6032; 0,6149)	(0,6551; 0,5171)
Erro E	0,2369 → **0,1529**	0,2882 → **0,1932**
Pesos que mexeram	v, b, linhas x_1 e x_4 de w	v, b, linhas x_1 e x_3 de w

O erro caiu nas duas iterações, e cada saída andou na direção do seu alvo.

A PEGADINHA

Aprender o Bart bagunçou o Homer

Homer testado	y_1 (alvo 1)	y_2 (alvo 1)	Erro E
Depois da iteração 1	0,6032	0,6149	0,1529
Depois da iteração 2	0,6788	0,5003	**0,1764**

- A saída "Adulto?" do Homer despencou de 0,6149 para 0,5003.
- Os pesos são compartilhados: ajustar pro Bart mexe na resposta do Homer.
- Por isso treinamos em épocas: repetimos todos os exemplos muitas vezes, até a rede achar pesos que servem pra todo mundo.

Repetindo tudo (Peter, Stewie, de novo...)



Mesma rede, mesmo η = 2, simulada na mão do computador: na época 15 os quatro já estão do lado certo.