Aulas 07-09

Métricas de Classificação

🎯 Atividade 1

Vocês são cientistas de dados contratados por uma imobiliária. A empresa quer um sistema que estime o valor de imóveis a partir de características da região, para agilizar avaliações. Sua dupla precisa entregar um modelo de regressão linear e provar, com números, que ele é confiável.

Dataset

California Housing (dataset público, real, já embutido no scikit-learn)

```
from sklearn.datasets import fetch_california_housing
dados = fetch_california_housing(as_frame=True)
df = dados.frame
```

Contém dados de bairros da Califórnia: renda média, idade média dos imóveis, número médio de cômodos, população, localização (latitude/longitude) e o valor médio das casas (MedHouseVal) — este último é o que vocês vão prever.

Exercícios

1) Quais são os atributos (colunas) desse dataset?

2) Quantas linhas (imóveis/bairros) ele tem?

3) Qual atributo será o y (alvo)? Por quê?

4) Existe algum valor ausente no dataset? Como vocês verificaram?

5) Seria necessário normalizar os dados antes de treinar uma regressão linear simples com apenas uma variável? Justifiquem.

6) Escolham um único atributo (x) que a equipe acredita ser o melhor preditor do valor do imóvel. Justifiquem a escolha antes de rodar qualquer código.

7) Façam um gráfico de dispersão desse atributo contra MedHouseVal. A relação parece linear?

8) Separem os dados em treino (80%) e teste (20%) usando train_test_split. Por que não podemos avaliar o modelo com os mesmos dados usados no treino?

9) Treinem um LinearRegression com o atributo escolhido.

10) Qual foi o valor do coeficiente (model.coef_) e do intercepto (model.intercept_)? Expliquem o que eles significam em português, com uma frase sobre imóveis (ex: "a cada unidade a mais de X, o valor sobe/desce Y").

11) Calculem o MSE e o R^2 do modelo no conjunto de teste.

12) O R^2 obtido indica um modelo forte, médio ou fraco? Comparem com o critério visto em aula.

🔥 **Desafio bônus**

13) Troquem o atributo escolhido por outro e repitam o treino. O R^2 melhorou ou piorou? Qual equipe da sala conseguiu o maior R^2 com uma única variável?

🎯 Atividade 2

É 1912. Vocês são analistas contratados (retroativamente!) para entender quem tinha mais chance de sobreviver ao naufrágio do Titanic, a partir de dados dos passageiros. A White Star Line quer um relatório com um classificador e métricas que expliquem os acertos e, principalmente, os erros do modelo.

Dataset

Titanic — Machine Learning from Disaster (dataset público clássico)

```
import pandas as pd
url = "https://raw.githubusercontent.com/datasciencedojo/datasets/master/
titanic.csv"
df = pd.read_csv(url)
```

Exercícios

1) Quais atributos existem no dataset? Quais parecem relevantes para prever sobrevivência e quais parecem irrelevantes (ex: nome, número do bilhete)?

2) Quantos passageiros sobreviveram e quantos não sobreviveram? (.value_counts()) — as classes estão balanceadas ou desbalanceadas?

3) Existem valores ausentes? Em qual(is) coluna(s)?

4) Proponham (em texto, sem precisar codar uma solução complexa) uma forma simples de lidar com os valores ausentes de idade.

5) A coluna Sex está em texto ("male"/"female"). Ela precisa virar número para o modelo funcionar — como vocês fariam isso? (dica: relembrem a Aula 06)

6) Escolham 2 ou 3 atributos (X) que a dupla aposta como bons preditores de sobrevivência. Justifiquem a aposta antes de treinar o modelo.

7) Separem em treino/teste. Qual proporção vocês escolheram e por quê?

8) Treinem uma LogisticRegression com os atributos escolhidos.

9) Peguem um passageiro específico do conjunto de teste e usem predict_proba para ver a probabilidade de sobrevivência dele. O resultado faz sentido dado o perfil da pessoa (classe, sexo, idade)?

10) Gerem a matriz de confusão. Quantos foram VP, VN, FP e FN?

11) Calculem acurácia, precisão, recall e F1-score.

12) Se o "erro" mais grave para esse relatório histórico fosse prever que alguém sobreviveria quando na verdade não sobreviveu (falso positivo), qual métrica a dupla priorizaria para julgar o modelo?

🔥 **Desafio bônus**

13) Adicionem mais um atributo ao modelo (ex: Fare ou Pclass) e comparem o F1-score antes e depois. Qual equipe da sala conseguiu o maior F1-score?

🔥 **Duelo entre equipes**

14) Troquem o conjunto de atributos escolhido com a dupla vizinha (sem mostrar o código, só o resultado) e tentem adivinhar quais atributos ela usou, a partir da matriz de confusão dela.